Univerzita Jana Evangelisty Purkyně
v Ústí nad Labem
Přírodovědecká fakulta



Systém pro monitorování a analýzu dopravy pomocí počítačového vidění

BAKALÁŘSKÁ PRÁCE

Vypracoval: Patrik Poklop

Vedoucí práce: Ing. Roman Vaibar Ph.D., MBA

Studijní program: Aplikovaná informatika

Studijní obor: Api

Ústí nad Labem 2026

Namísto žlutých stránek vložte digitálně podepsané zadání kvalifikační práce poskytnuté vedoucím katedry.
Zadání musí zaujímat právě dvě strany.

Zadání je nutno vložit jako PDF pomocí některého nástroje, který umožňuje editaci dokumentů (se zachováním elektronického podpisu).

V Linuxe lze například použít příkaz `pdftk`.

Prohlášení

Prohlašuji, že jsem tuto bakalářskou práci vypracoval samostatně a použil jen pramenů, které cituji a uvádím v přiloženém seznamu literatury.

Byl jsem seznámen s tím, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., ve znění zákona č. 81/2005 Sb., autorský zákon, zejména se skutečností, že Univerzita Jana Evangelisty Purkyně v Ústí nad Labem má právo na uzavření licenční smlouvy o užití této práce jako školního díla podle § 60 odst. 1 autorského zákona, a s tím, že pokud dojde k užití této práce mnou nebo bude poskytnuta licence o užití jinému subjektu, je Univerzita Jana Evangelisty Purkyně v Ústí nad Labem oprávněna ode mne požadovat přiměřený příspěvek na úhradu nákladu, které na vytvoření díla vynaložila, a to podle okolností až do jejich skutečné výše.

V Ústí nad Labem dne 26. října 2026 Podpis: . . . . . .

Děkuji vedoucímu práce Ing. Romanu Vaibarovi, Ph.D., MBA
za neocenitelné rady a pomoc při tvorbě bakalářské práce.

Systém pro monitorování a analýzu dopravy pomocí počítačového vidění

Abstrakt:

Tato bakalářská práce se zabývá návrhem, implementací a vyhodnocením systému pro monitorování a analýzu silniční dopravy pomocí metod počítačového vidění. Cílem práce je vytvořit funkční prototyp zařízení schopného v reálném čase analyzovat videozáznam z dopravní lokality, detekovat a klasifikovat účastníky provozu (primárně osobní automobily, autobusy a nákladní vozidla, případně chodce) a zaznamenávat jejich průjezdy definovanou oblastí zájmu (ROI). Navržený systém je realizován na platformě Raspberry Pi 5 s využitím dedikovaného AI akcelerátoru Hailo-8 a moderních detekčních modelů rodiny YOLO. Součástí práce je také softwarová aplikace pro ukládání záznamů do relační databáze a jejich interaktivní vizualizaci. Funkčnost, výpočetní výkon a přesnost systému jsou ověřeny pomocí experimentů nad reálným dopravním záznamem za zhoršených povětrnostních podmínek a porovnány s referenčním řešením na grafické kartě (GPU) i manuálním pozorováním.

Klíčová slova: počítačové vidění, monitorování dopravy, detekce objektů, Edge AI, Raspberry Pi

System for Traffic Monitoring and Analysis using Computer Vision

Abstract:

This bachelor's thesis focuses on the design, implementation, and evaluation of a road traffic monitoring and analysis system using computer vision methods. The aim of the thesis is to develop a functional prototype capable of real-time video analysis of a traffic scene, including the detection and classification of traffic participants (primarily passenger cars, buses, and trucks, as well as pedestrians) and counting their movements across a defined region of interest (ROI). The proposed system is implemented on the Raspberry Pi 5 platform using the Hailo-8 AI accelerator and modern YOLO object detection models. The thesis also includes the development of a software application for relational database storage and interactive data visualization. The functionality, computational performance, and accuracy of the system are verified through experiments on real-world winter traffic footage and evaluated against both a reference GPU implementation and manual ground truth observations.

Keywords: computer vision, traffic monitoring, object detection, Edge AI, Raspberry Pi

Obsah

Seznam zkratek **12**

Úvod **15**

1. Teoretická část **17**
1.1. Sledování a počítání objektů 17
1.2. Počítačové vidění pro analýzu dopravy 22
1.3. Přehled detekčních modelů 26
1.4. Systémy pro monitorování dopravy 28
1.5. Edge AI a vestavěné systémy 30
1.6. Metodika testování a evaluace 34
1.7. Etické aspekty a GDPR 36

2. Návrh systému **39**
2.1. Požadavky na systém 39
2.2. Celková architektura a tok dat 39
2.3. Výběr hardwaru 40
2.4. Návrh softwarových modulů 41

3. Implementace systému **47**
3.1. Konfigurace prostředí a automatizace běhu 47
3.2. Příprava a kompilace detekčního modelu 48
3.3. Implementace zpracování videa a detekce 49
3.4. Komunikace, ukládání a vizualizace dat 52

4. Testování a vyhodnocení **55**
4.1. Testovací scénáře a vliv oblasti zájmu (ROI) 55
4.2. Vyhodnocení přesnosti detekce a matice záměn 56
4.3. Vyhodnocení přesnosti sčítání a klasifikace 57
4.4. Vyhodnocení výkonnosti systému 58

5. Diskuze a prezentace výsledků **61**

6. Závěr **63**

A. Externí přílohy **69**

Seznam zkratek

ARM Advanced RISC Machine (Architektura energeticky úsporných procesorů)

CPU Central Processing Unit (Centrální procesorová jednotka)

DeepSORT Deep Simple Online and Realtime Tracking (Rozšíření algoritmu SORT o hluboké učení)

Edge AI Edge Artificial Intelligence (Umělá inteligence na okraji sítě / lokální zpracování modelů na koncových zařízeních)

FPS Frames Per Second (Počet zpracovaných snímků za sekundu)

GDPR General Data Protection Regulation (Obecné nařízení o ochraně osobních údajů)

GPU Graphics Processing Unit (grafický procesor)

HTTP Hypertext Transfer Protocol (Hypertextový přenosový protokol)

ID Identifier (Identifikátor / Unikátní označení objektu)

IoU Intersection over Union (Metrika prostorového překryvu detekcí)

IP Internet Protocol (Internetový protokol pro přenos dat po síti)

MOT Multiple Object Tracking (Víceobjektové sledování)

NPU Neural Processing Unit (Neuronový procesor pro akceleraci umělé inteligence)

ONVIF Open Network Video Interface Forum (Globální standard pro komunikaci IP kamer)

PCIe Peripheral Component Interconnect Express (Vysokorychlostní počítačová sběrnice)

PoE Power over Ethernet (Technologie pro napájení zařízení po datovém kabelu)

R-CNN Region-based Convolutional Neural Network (Architektura dvoufázové detekce objektů)

RAM Random Access Memory (operační paměť s přímým přístupem)

ROI Region of Interest (Oblast zájmu / sledovaný výřez v obraze)

RTSP Real-Time Streaming Protocol (Síťový protokol pro přenos streamovaného videa)

SORT Simple Online and Realtime Tracking (Algoritmus pro online sledování v reálném čase)

SSD Single Shot MultiBox Detector (Architektura jednofázové detekce objektů)

YOLO You Only Look Once (Architektura jednofázové detekce objektů)

Úvod

Rostoucí intenzita dopravy představuje jednu z hlavních výzev současných měst a aglomerací. Zvyšující se počet vozidel klade vysoké nároky nejen na propustnost samotné dopravní infrastruktury, ale také na bezpečnost silničního provozu a celkovou kvalitu života obyvatel. Efektivní řízení a plánování dopravy proto vyžaduje přesná, kontinuálně sbíraná a aktuální data. Tradiční metody získávání těchto dat, jako je například manuální sčítání dopravy, jsou však časově i personálně náročné a náchylné k chybám. Vzniká tak silná potřeba automatizace celého procesu.

V reakci na tyto potřeby a v rámci širšího rozvoje konceptu chytrých měst (z angl. *Smart Cities*) se jako vysoce efektivní řešení ukazuje využití moderních technologií. Klíčovým nástrojem se v tomto kontextu stává počítačové vidění v kombinaci s umělou inteligencí. Kamerové systémy doplněné o algoritmy strojového učení poskytují flexibilní a škálovatelné řešení pro automatizované sledování, vyhodnocování a predikci dopravních jevů. Jejich hlavní výhodou je možnost nasazení v reálném prostředí stávajících komunikací bez nutnosti rozsáhlých a nákladných stavebních zásahů do infrastruktury.

S překotným rozvojem výpočetních technologií a hardwarové miniaturizace se v této oblasti navíc stále více prosazuje přístup tzv. Edge AI (umělá inteligence na okraji sítě). Zpracování rozsáhlých obrazových dat díky tomu již nemusí probíhat ve vzdálených datacentrech, ale je realizováno přímo na okrajových zařízeních v místě sběru dat. Využití kompaktních jednodeskových počítačů doplněných o specializované hardwarové AI akcelerátory umožňuje dramatické snížení latence, zvýšení ochrany citlivých osobních údajů a minimalizaci závislosti na stabilním internetovém připojení či cloudových službách. V dopravních aplikacích, kde je vyžadováno spolehlivé zpracování v reálném čase, je tento přístup zásadní.

Cílem této bakalářské práce je navrhnout, implementovat a otestovat plně funkční systém pro automatické sčítání a analýzu dopravního provozu, postavený na principech Edge AI. Práce se zaměřuje na detekci, sledování a klasifikaci různých účastníků provozu – primárně osobních automobilů, autobusů a nákladních vozidel, případně chodců v definované lokalitě s využitím moderních detekčních modelů pro víceobjektové sledování. Důraz je kladen na praktickou realizaci celého řešení na dostupném okrajovém zařízení a na následné vyhodnocení přesnosti detekce i sčítání z reálných videozáznamů dopravy.

Text práce je strukturován do šesti hlavních kapitol. První, část teoretická poskytuje ucelený přehled v oblastech počítačového vidění, metod detekce a sledování objektů a existujících systémů pro monitorování dopravy. Následně se věnuje specifikům Edge AI a etickým aspektům sběru dat. Druhá kapitola přibližuje celkový návrh architektury systému, včetně zdůvodnění výběru

hardwarových komponent. Třetí kapitola detailně popisuje samotnou implementaci řešení od přípravy vývojového prostředí až po ukládání a vizualizaci nasbíraných dat. Čtvrtá a pátá kapitola jsou dedikovány testování systému v reálných scénářích, vyhodnocení přesnosti modelu a diskuzi nad dosaženými výsledky. Závěrečná kapitola pak shrnuje zjištěné poznatky a nastiňuje možnosti budoucího rozvoje vytvořené aplikace.

1. Teoretická část

1.1. Sledování a počítání objektů

Sledování objektů v obrazových sekvencích a videu představuje klíčovou nadstavbu nad samotnou detekcí objektů. Zatímco detekce umožňuje lokalizovat a klasifikovat objekty v jednotlivých izolovaných snímcích, sledování zajišťuje jejich konzistentní identifikaci napříč časem. Tato vlastnost je vysoce heterogenní a zásadní zejména v dopravních aplikacích, kde je pro komplexní analýzu nutné sledovat plynulý pohyb vozidel, určovat jejich trajektorie, rychlost nebo měřit přesný počet průjezdů daným úsekem komunikace [1, 2].

Víceobjektové sledování (MOT)

Víceobjektové sledování (MOT, z angl. *Multiple Object Tracking (Víceobjektové sledování)*) se zabývá současným sledováním většího počtu dynamických objektů ve scéně. Hlavním cílem je přiřazení unikátních a časově konzistentních identifikátorů (Unique ID) každému objektu při jeho prvním výskytu ve scéně. Tento identifikátor je následně udržován po celou dobu výskytu entity ve sledované sekvenci, což umožňuje spojování detekcí mezi jednotlivými snímky a rekonstrukci trajektorie objektu v čase. V dopravních monitorovacích systémech nachází MOT uplatnění zejména při analýze dopravních toků, odhadu hustoty provozu, detekci anomálií nebo sledování pohybu vozidel a chodců na komplexních křižovatkách [2].

Tento proces je ve většině moderních architektur realizován pomocí přístupu „detekce před sledováním“ (z angl. *Tracking-by-Detection*). Systém nejprve v každém snímku identifikuje objekty pomocí detekčního konvolučního modelu a následně provádí asociaci těchto detekcí mezi po sobě jdoucími snímky na základě kombinace prostorových, časových a vzhledových charakteristik. Správná správa těchto identifikátorů je kritická pro následné navazující úlohy, jako je statistické počítání objektů nebo pokročilá analýza jejich chování [1].



Obrázek 1.1.: Ukázka víceobjektového sledování vozidel s přiřazenými časově konzistentními identifikátory (vlastní zpracování, akcelerátor Hailo-8)

Jak je znázorněno na obrázku 1.1, implementovaný systém umožňuje stabilní sledování většího množství objektů v reálném čase, přičemž každému vozidlu zůstává zachováno jeho unikátní číslo i při pohybu napříč snímanou scénou.

Algoritmy pro sledování objektů

Mezi nejpoužívanější a nejefektivnější přístupy pro sledování objektů v reálném čase patří algoritmy SORT a DeepSORT. Tyto metody jsou oblíbené zejména pro svou nízkou výpočetní náročnost, vysokou propustnost a snadnou integraci s moderními detekčními modely, jako je rodina modelů YOLO (z angl. *You Only Look Once (Architektura jednofázové detekce objektů)*) [3].

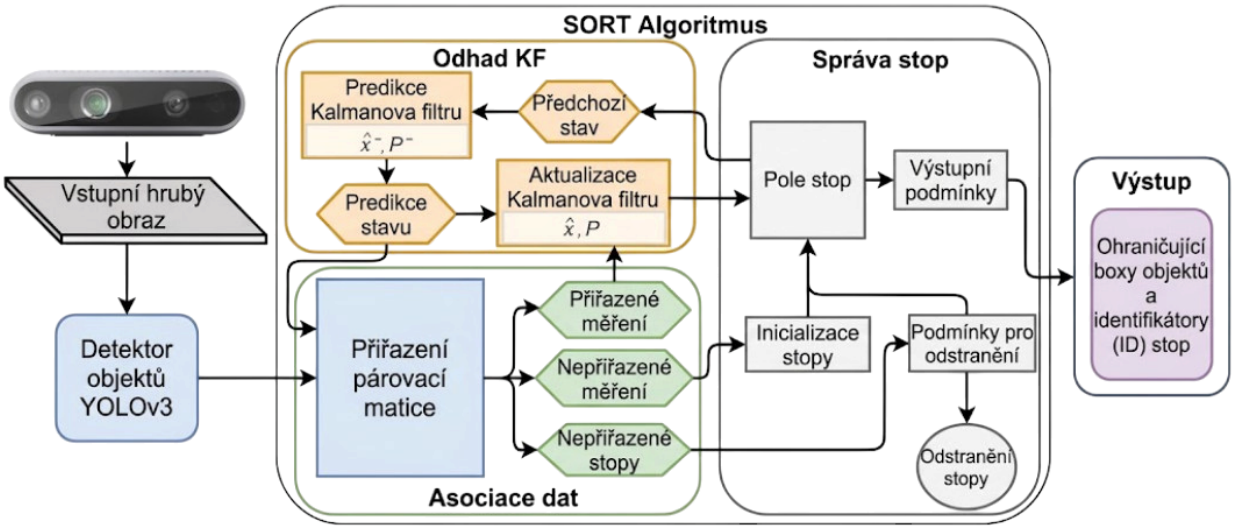
SORT

Algoritmus SORT (z angl. *Simple Online and Realtime Tracking (Algoritmus pro online sledování v reálném čase)*) je postaven na kombinaci dvou klíčových komponent: Kalmanova filtru[1] a Maďarského algoritmu pro datovou asociaci. Kalmanův filtr slouží k predikci budoucí polohy objektu v následujícím snímku na základě lineárního pohybového modelu. Stav každého sledovaného objektu je definován vektorově pomocí souřadnic středu ohraničujícího obdélníku, jeho plochy (měřítka), poměru stran a jejich příslušných rychlostí změn v čase.

Jakmile jsou v novém snímku získány čerstvé detekce, nastupuje Maďarský algoritmus, který řeší optimalizační úlohu přiřazení predikovaných poloh k reálným novým detekcím. Jako nákladová

[1]Kalmanův filtr je rekurzivní matematický algoritmus, který ze série nepřesných a zašuměných měření (v tomto případě historických detekcí z kamery) odhaduje aktuální a predikuje budoucí stav dynamického systému (například polohu, směr a rychlost jedoucího vozidla).

funkce (metrika vzdálenosti) se zde využívá překryv ohraničujících obdélníků vyjádřený pomocí metriky (IoU, z angl. *Intersection over Union (Metrika prostorového překryvu detekcí)*). Díky této matematické přímočarosti dosahuje SORT extrémní rychlosti zpracování, avšak jeho zásadní nevýhodou je nestabilita při dlouhodobějších překryvech (okluzích) objektů, kdy absence vizuální informace často vede ke ztrátě stopy a fatálnímu selhání přiřazení ID. [4].



Obrázek 1.2.: Celkový přehled a princip fungování sledovacího algoritmu SORT (vlastní překlad, adaptováno z [5, s. 5]).

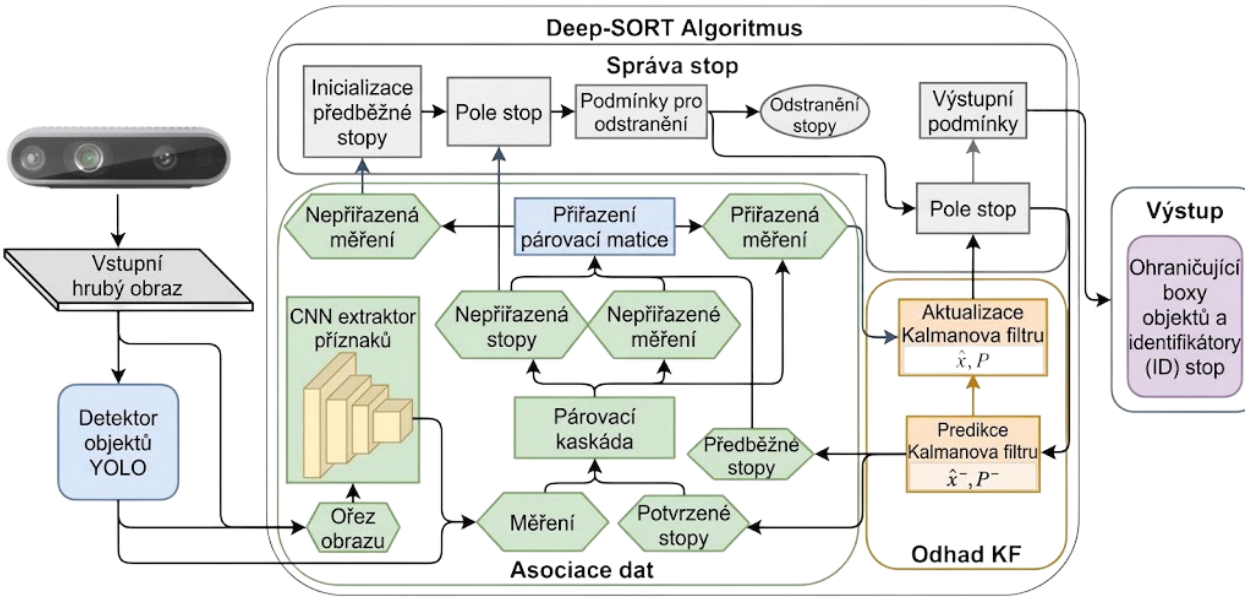
Na obrázku 1.2 je detailně znázorněna celá pracovní smyčka (z angl. *pipeline*) algoritmu SORT [4], která se nezávisle opakuje s každým novým obrazovým snímkem. Podle blokového schématu lze celý proces logicky rozdělit do tří na sebe navazujících fází:

1. **Odhad KF:** Tato část schématu představuje paměť systému. Na základě předchozího stavu (*Předchozí stav*) algoritmus provede matematickou predikci (*Predikce Kalmanova filtru*), čímž získá odhadovanou polohu sledovaných objektů v aktuálním čase (*Predikce stavu*).
2. **Asociace dat:** Do tohoto bloku vstupují jak odhadnuté polohy z Kalmanova filtru, tak zcela nové detekce z modelu YOLO. Úkolem párovací matice (*Přiřazení párovací matice*) je optimálně spojit tyto dva vstupy pomocí metriky IoU. Výstupem jsou tři možné stavy: úspěšně spárovaná měření (*Přiřazené měření*), nové detekce bez historie (*Nepřiřazené měření*) a existující stopy, ke kterým se nenašla nová detekce (*Nepřiřazené stopy*).
3. **Správa stop:** V závěrečné fázi systém reaguje na výsledky předchozí asociace. Spárovaná měření aktualizují Kalmanův filtr a udržují se v poli aktivních stop (*Pole stop*). Z nespárovaných měření, což typicky představuje nově příchozí vozidla, se inicializují stopy nové (*Inicializace stopy*). Nespárované stopy, tedy vozidla, která pravděpodobně opustila scénu, jsou po splnění stanovených podmínek ze systému odstraněny (*Odstranění stopy*). Validní stopy jsou následně propuštěny na finální výstup (*Výstup*).

DeepSORT

Algoritmus DeepSORT (z angl. *Deep Simple Online and Realtime Tracking (Rozšíření algoritmu SORT o hluboké učení)*) vznikl jako přímá reakce na slabá místa původního algoritmu SORT v komplexních a hustých scénách. Rozšiřuje čistě geometrické a prostorové přiřazování o integraci hlubokých konvolučních neuronových sítí, které jsou vytrénovány pro extrakci vizuálních vzhledových příznaků (z angl. *deep appearance descriptors*). Pro každý detekovaný objekt je vygenerován charakteristický vektor (embedding), který reprezentuje jeho vizuální identitu.

Při samotné asociaci dat pak DeepSORT kombinuje dvě metriky: Mahalanobisovu vzdálenost, která reflektuje pohybovou konzistenci na základě Kalmanova filtru, a kosinovou vzdálenost, jež vyhodnocuje shodu vizuálních příznaků s historií daného objektu. Propojení těchto informací probíhá pomocí kaskádového párování (*matching cascade*). Tento kombinovaný přístup dramaticky zvyšuje robustnost sledování v hustém dopravním provozu, kde dochází k častému vzájemnému zakrývání vozidel, a prokazatelně minimalizuje množství chyb typu záměny identity (*ID switches*) [6].



Obrázek 1.3.: Blokové schéma architektury sledovacího algoritmu DeepSORT a jeho rozhodovacích kroků (vlastní překlad, adaptováno z [5, s. 7])

Na obrázku 1.3 je detailně znázorněna architektura a datový tok algoritmu Deep-SORT. Podle blokového schématu lze celý proces rozdělit do následujících klíčových fází, které se vykonávají s každým novým snímkem:

1. **Extrakce příznaků a predikce polohy:** Vstupní obraz (*Vstupní hrubý obraz*) je nejprve zpracován detektorem objektů, ze kterého jsou získány obrazové výřezy jednotlivých vozidel (*Ořez obrazu*). Tyto výřezy následně zpracovává konvoluční neuronová síť (*CNN extraktor příznaků*), jež extrahuje unikátní vizuální příznaky. Souběžně s tím modul odhadu (*Odhad KF*) provádí matematickou predikci budoucí polohy pomocí Kalmanova filtru (*Predikce Kalmanova filtru*).

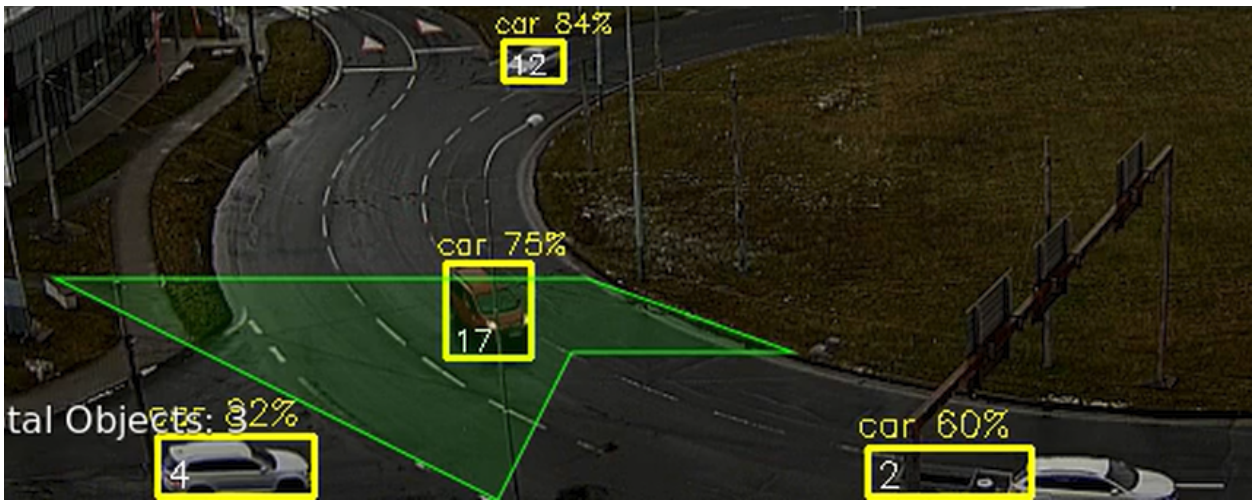
2. **Asociace dat:** Tento centrální modul kombinuje nová měření obohacená o vizuální příznaky (*Měření*) a potvrzené stopy z minulosti (*Potvrzené stopy*). Klíčovým inovačním prvkem oproti původnímu algoritmu SORT je kaskádové párování (*Párovací kaskáda*), které prioritně využívá právě vizuální podobnost. Objekty a měření, které kaskáda nedokáže spojit (*Nepřiřazené stopy* a *Nepřiřazená měření*), jsou zachyceny a předány do klasické párovací matice (*Přiřazení párovací matice*), jež funguje jako záloha využívající standardní prostorový překryv.
3. **Správa stop a aktualizace:** Výstupy z asociace dat se dělí do tří směrů. Úspěšně spárovaná měření (*Přiřazená měření*) jsou využita k okamžité aktualizaci Kalmanova filtru (*Aktualizace Kalmanova filtru*). Zcela nová detekovaná vozidla, která nemají historii (*Nepřiřazená měření*), zakládají v systému nové, zatím nepotvrzené stopy (*Inicializace předběžné stopy*). Správa stop následně kontroluje celé pole aktivních záznamů (*Pole stop*). Vozidla, jež dlouhodobě chybí a splní podmínky pro smazání (*Podmínky pro odstranění*), jsou ze systému odstraněna (*Odstranění stopy*). Stopy splňující výstupní kritéria (*Výstupní podmínky*) jsou předány na finální výstup v podobě souřadnic a unikátních identifikátorů (*Výstup*).

Metody sčítání objektů

Samotné automatické sčítání objektů v dopravním proudu bezprostředně navazuje na výsledky získané z MOT. Namísto prosté kumulace detekcí v jednotlivých samostatných snímcích, která by vedla k masivnímu nadhodnocení výsledků (například z důvodu vícenásobného započítání téhož stojícího či pomalu jedoucího vozidla), se využívá analýzy časoprostorových trajektorií jednoznačně identifikovaných objektů [2].

V praxi se pro automatizované sčítání a kategorizaci využívají dva primární koncepční přístupy:

- **Virtuální čára (z angl. *Virtual Line*):** Jedná se o nejrozšířenější a výpočetně nejméně náročnou metodu pro sčítání vozidel v konkrétních jízdních pruzích či směrech. V obrazovém prostoru je definována úsečka fungující jako detekční brána. Systém v každém kroku kontroluje, zda vektor trajektorie konkrétního objektu (typickky reprezentovaný středovým nebo spodním bodem jeho ohraničujícího obdélníku) protnul tuto linii. V okamžiku detekce průsečíku je inkrementováno počítadlo pro daný směr jízdy. Tento přístup je vysoce efektivní pro stanovení okamžité intenzity dopravy na liniových úsecích komunikací [2].
- **Oblast zájmu (z angl. ROI):** Alternativní přístup spočívá ve vymezení uzavřené polygonální nebo obdélníkové zóny přímo v digitálním obraze. Sledovaný objekt je zaregistrován a statisticky započítán buď v momentě vstupu do této definované oblasti, nebo při jejím opuštění. Tento princip se využívá především v situacích, kde je nutné sledovat celkovou obsazenost určitého vyhrazeného prostoru (např. plochy křižovatek, odbočovací pruhy nebo parkoviště) či analyzovat průměrnou dobu zdržení vozidel v daném segmentu [1, 2].



Obrázek 1.4.: Definice analytické oblasti zájmu (ROI) pomocí polygonu v praktické implementaci sledovacího systému (vlastní zpracování, akcelerátor Hailo-8).

Jak ukazuje obrázek 1.4, zatímco na rovných úsecích komunikací často postačuje k detekci průjezdu jednoduchá virtuální čára, složitější dopravní uzly, jakými jsou kruhové objezdy, vyžadují robustnější přístup. V rámci předložené implementace je proto oblast zájmu (ROI) definována jako nepravidelný n-úhelník (polygon). Tento geometrický útvar je v systému konstruován pomocí přesné sady 2D souřadnic (vrcholů) definovaných v obrazovém prostoru předzpracovaného snímku.

Proces samotného sčítání a vyhodnocování trajektorií je následně založen na průběžném výpočtu prostorového průniku (z angl. *spatial intersection*). Systém v každém snímku kontinuálně extrahuje polohu sledovaných objektů, jež jsou typicky reprezentovány středovým bodem (centroidem) jejich ohraničujícího obdélníku. Jakmile vyhodnocovací algoritmus detekuje, že se tento referenční bod vozidla nachází přímo uvnitř definované polygonové zóny (což matematicky odpovídá úloze bodu v polygonu, tzv. *Point-in-Polygon*), je vozidlo okamžitě započítáno do celkové statistiky dopravy. Tento moment je na obrázku názorně zachycen u objektu s identifikátorem 17. Tento plošný přístup výrazně eliminuje chyby spojené s nepřesnostmi detekce na hranách a umožňuje spolehlivé sčítání i při zakřivených a překrývajících se trajektoriích.

1.2. Počítačové vidění pro analýzu dopravy

Počítačové vidění (z angl. *Computer Vision*) představuje interdisciplinární oblast informatiky, která se zabývá automatickou analýzou statických snímků a videozáznamů. Jeho hlavním cílem je extrakce relevantních a sémantických informací z vizuálních vstupů. V oblasti moderních dopravních systémů je počítačové vidění využíváno zejména v aplikacích dopravního dohledu, proaktivního řízení provozu a při automatické analýze dopravní propustnosti. Kamerové systémy umožňují kontinuální sledování dopravních toků, detekci anomálních situací nebo identifikaci konkrétních vozidel a jejich registračních značek [1, 2].

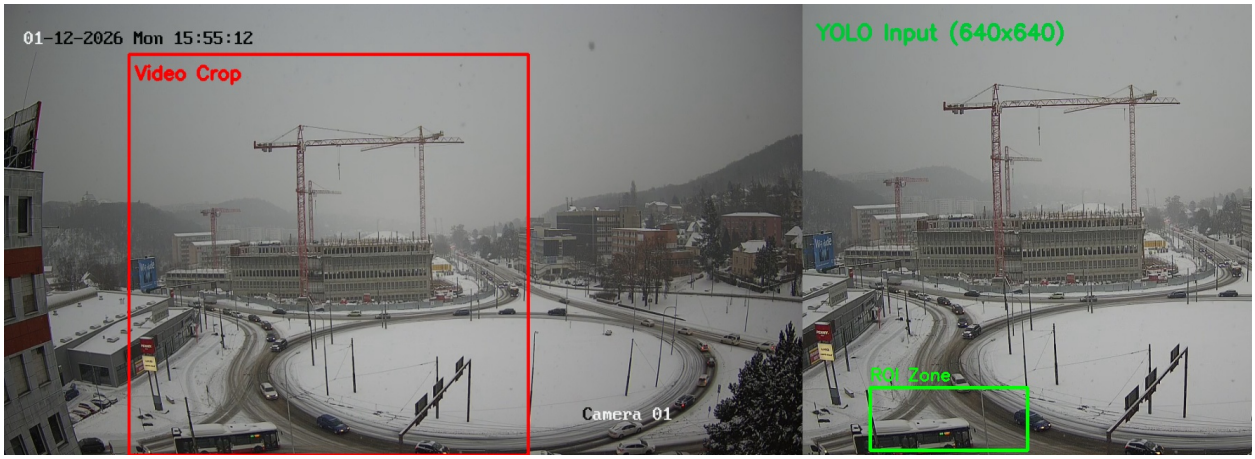
Předzpracování obrazu

Předzpracování obrazu představuje nezbytný přípravný krok před samotnou aplikací detekčních modelů. Cílem je zlepšení kvality vstupních dat, potlačení digitálního šumu a optimalizace celkové výpočetní zátěže.

V dopravních aplikacích je surový videozáznam z kamery často výpočetně příliš objemný a obsahuje velké množství irelevantních informací (např. oblohu, okolní budovy, chodníky). Prvním logickým krokem je proto definice oblasti zájmu (ROI, z angl. *Region of Interest (Oblast zájmu / sledovaný výřez v obraze)*). Softwarové oříznutí nebo zavedení masky zaručí, že systém analyzuje pouze samotnou vozovku. To nejen radikálně snižuje objem zpracovávaných dat, ale také eliminuje falešné detekce, jako jsou například zaparkovaná vozidla mimo zorné pole křižovatky.

Následně musí být upravený obraz transformován do formátu, který striktně vyžaduje architektura neuronové sítě. Jedná se primárně o **škálování (z angl. *resizing*)** na fixní rozlišení (typicky 640×640). Aby při změně velikosti nedošlo k deformaci poměru stran, což by zhoršilo schopnost sítě rozeznat tvar a proporce vozidla, využívá se běžně technika zvaná *letterboxing*. Ta zmenší obraz proporcionálně a chybějící prostor (okraje) doplní neutrální barvou.

Poslední rutinní fází je **normalizace barev**. Hodnoty jednotlivých pixelů, které standardně nabývají celočíselných hodnot 0 až 255, jsou převedeny na desetinná čísla v intervalu 0,0 až 1,0. Tento krok stabilizuje a výrazně urychluje matematické výpočty (násobení matic) uvnitř umělé neuronové sítě [1]. I přes tuto důkladnou datovou optimalizaci však analýza obrazu zůstává nesmírně výpočetně náročná, což představuje hlavní výzvu při nasazení na okrajových zařízeních.



Obrázek 1.5.: Příklad dvoufázového vymezení oblasti zájmu, hardwarový ořez vlevo a softwarová analytická zóna vpravo (vlastní zpracování).

Jak ukazuje obrázek 1.5, předzpracování obrazového toku hraje klíčovou roli v optimalizaci celého systému. Namísto výpočetně náročnějších metod (jako je doplňování černých pruhů u *letterboxingu*) je v navrženém systému využit přímý prostorový ořez obrazu (z angl. *crop*). Levá část obrázku znázorňuje zdrojový snímek, který byl v rámci datovodu nejprve naškálován na rozlišení 1280×720 pixelů. Červený obdélník v něm přesně vymezuje hranice hardwarového

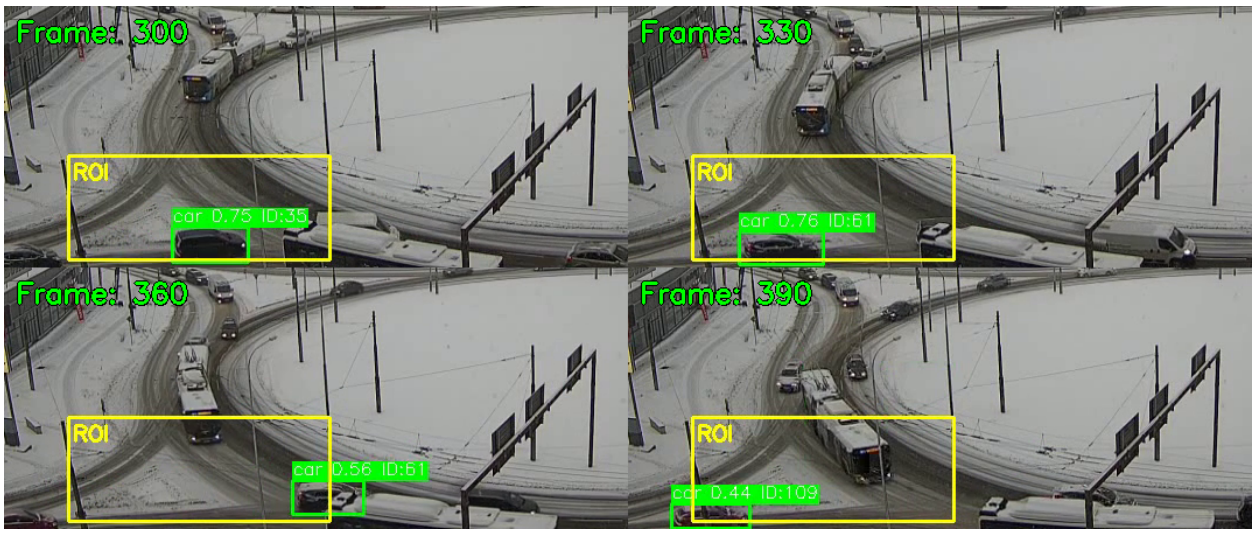
ořezu ten je definován počátečními souřadnicemi $x = 200, y = 80$ s pevnou šířkou a výškou 640 pixelů.

Pravá část následně představuje fyzicky vyříznutý čtverec, jenž svými rozměry (640×640) nativně odpovídá požadavkům vstupní vrstvy modelu YOLO. Je nutné zdůraznit, že tento hardwarový ořez slouží výhradně k obrazové přípravě dat před vstupem do modelu. Samotná analytická oblast zájmu (ROI), která určuje, kde reálně dochází k detekci a sčítání vozidel, je v systému definována až následně. Na pravé části obrázku je tato aplikační logika vizualizována zeleným obdélníkem. Jeho poloha je v aplikačním kódu dynamicky vypočítávána pomocí relativních souřadnic vůči velikosti předzpracovaného výstupu (v tomto konkrétním případě $x = 96, y = 544, w = 224, h = 90$). Oddělením těchto dvou fází je do neuronové sítě propuštěn čistší datový tok, přičemž analytika si zachovává plnou flexibilitu.

Základní úlohy počítačového vidění

V rámci analýzy dopravy a návrhu inteligentní dopravní infrastruktury se počítačové vidění opírá o tři základní, na sebe úzce navazující úlohy:

- **Detekce objektů:** Zaměřuje se na samotnou lokalizaci objektů v obraze. Výstupem této úlohy jsou obvykle ohraničující obdélníky (z angl. *bounding boxes*), které vymezují prostorovou polohu nalezených entit. V dopravních aplikacích se jedná především o detekci vozidel, chodců nebo cyklistů.
- **Klasifikace objektů:** Představuje úlohu, při které je již detekovanému objektu přiřazena předem definovaná třída na základě jeho vizuálních charakteristik. V praxi se využívá například pro rozlišení, zda je detekované vozidlo osobní automobil, nákladní vůz nebo autobus [1].
- **Sledování objektů:** Umožňuje analyzovat pohyb detekovaných a klasifikovaných objektů napříč po sobě jdoucími snímky video sekvence. Slouží k odhadu trajektorií, predikci směru a výpočtu rychlosti pohybu [2].



Obrázek 1.6.: Časová sekvence čtyř snímků demonstrující kontinuální sledování objektů a vyhodnocování jejich polohy vůči definované zóně (ROI). Systém úspěšně udržuje ID u projíždějícího automobilu a dynamicky registruje nová vozidla (vlastní zpracování, inference na GPU).

Jak je názorně ukázáno na obrázku 1.6, propojení úlohy detekce a sledování umožňuje systému přidělit jednotlivým vozidlům unikátní identifikátory (ID) a kontinuálně je sledovat v čase. Obrázek zachycuje sekvenci čtyř po sobě jdoucích snímků s pevným rozestupem 30 rámečků (snímky 300, 330, 360 a 390). Vzhledem k tomu, že zdrojové video je zpracováváno frekvencí 15 snímků za sekundu (FPS), představuje časový krok mezi každým zobrazeným dílčím obrázkem přesně 2 sekundy reálného času (celá mřížka tak mapuje celkem 6 sekund dopravního provozu). Pro každé detekované vozidlo systém neustále vypočítává středový bod (centroid) jeho ohraničujícího obdélníku. Zásadní analytickou podmínkou je, že vozidlo je do statistik průjezdů aktivně zahrnuto pouze tehdy, nachází-li se tento vypočítaný střed fyzicky uvnitř definované oblasti zájmu (žlutý obdélník ROI).

Plynulý průjezd a spolehlivost sledování jsou prokazatelně demonstrovány na osobním automobilu (označeném jako *car ID:61*). Toto vozidlo je zachyceno ve sledované zóně ROI ve snímku 330, přičemž o dvě sekundy později (snímek 360) si systém navzdory jeho pohybu napříč křižovatkou úspěšně udržuje jeho původní ID. Z mřížky je rovněž jasně patrné, jak algoritmus dynamicky reaguje na celkovou obměnu vozidel ve scéně. Zatímco na prvním snímku (300) zónou projíždí předchozí vozidlo s ID 35, na posledním snímku (390) do ROI zleva vstupuje další automobil, kterému systém okamžitě a správně přiděluje nové, dosud nepoužité ID (109). Tento holistický přístup, kombinující striktní prostorové omezení analytickou zónou a konzistentní sledování identity napříč snímky, je v dopravních aplikacích naprosto klíčový pro zabránění falešnému vícenásobnému započítání téhož objektu.

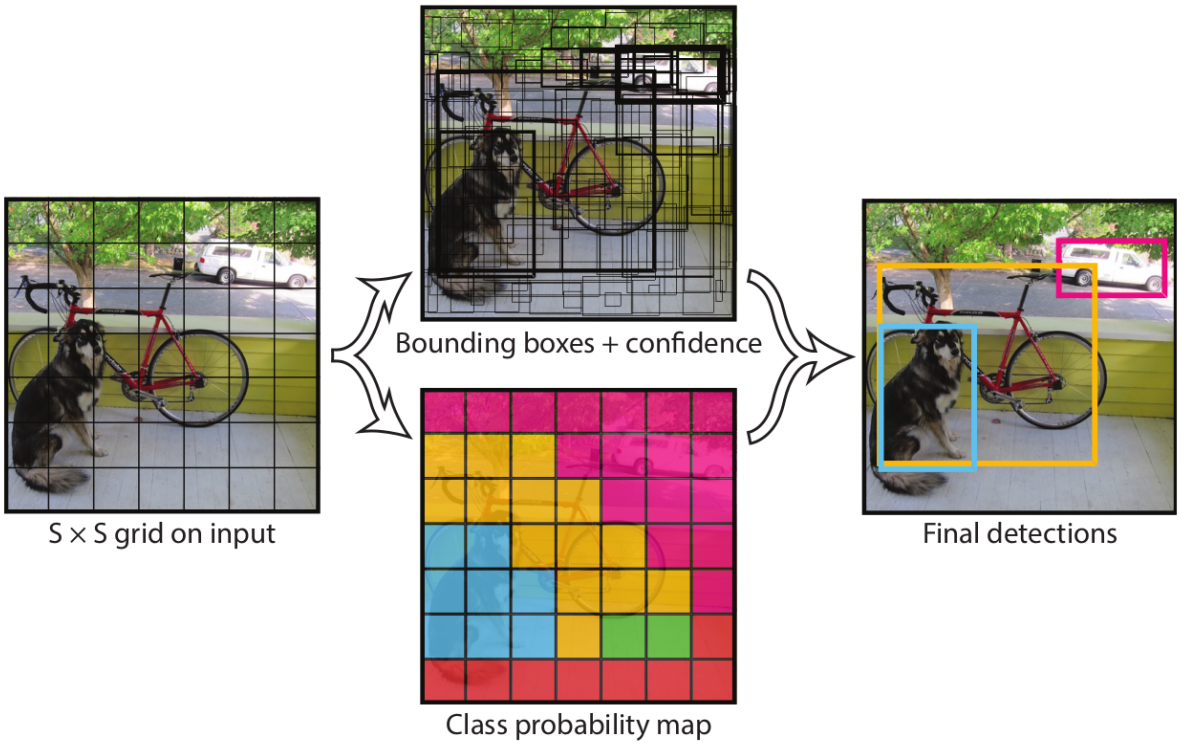
1.3. Přehled detekčních modelů

V posledních letech dominují oblasti detekce objektů architektury hlubokých konvolučních neuronových sítí (CNN). Pro nasazení na výpočetně omezených okrajových zařízeních se historicky osvědčily zejména modely z rodiny SSD a YOLO, které patří do kategorie tzv. jednofázových detektorů (z angl. *one-stage detectors*). Tyto modely dokáží obraz zpracovat během jediného průchodu sítí, čímž splňují výše zmíněné požadavky na nízkou latenci.

Architektura SSD (z angl. *Single Shot MultiBox Detector (Architektura jednofázové detekce objektů)*) detekuje objekty tak, že využívá hustou sadu předem definovaných kotevních obdélníků (z angl. *anchor boxes*) o různých poměrech stran a velikostech. Predikce probíhá na několika mapách příznaků s různým rozlišením současně, což modelu teoreticky umožňuje lépe zachytit objekty nejrůznějších velikostí [1].

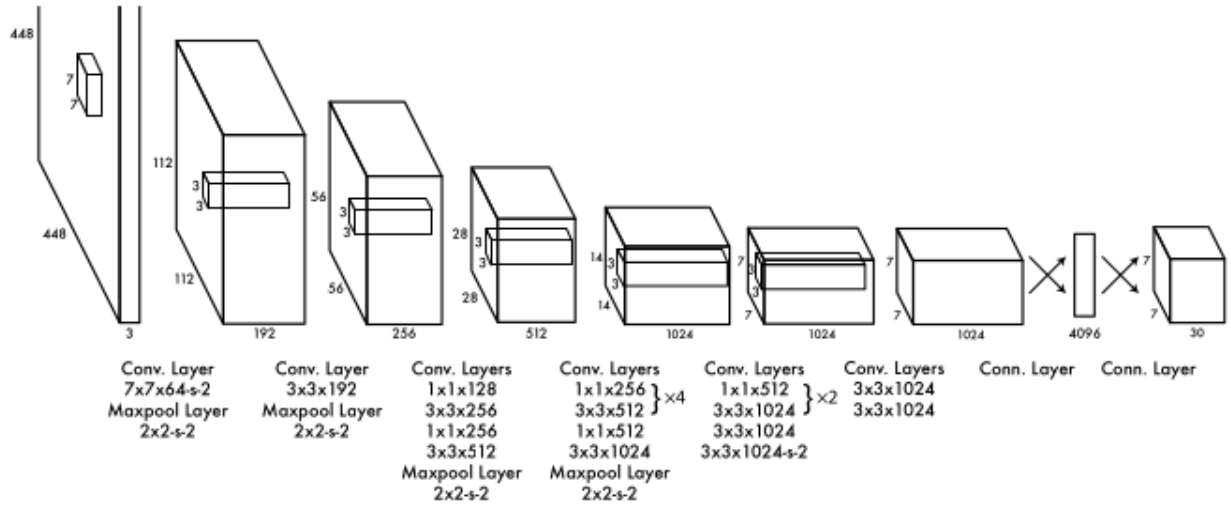
Model YOLO

Ačkoliv SSD dosahuje stabilní přesnosti, naprostou revoluci v efektivitě přinesla architektura YOLO (z angl. *You Only Look Once (Architektura jednofázové detekce objektů)*), která od základů transformovala přístup k počítačovému vidění. Namísto dvoufázového generování návrhů oblastí (jako u starších sítí R-CNN (z angl. *Region-based Convolutional Neural Network (Architektura dvoufázové detekce objektů)*)) formuluje detekci jako jedinou, *end-to-end* regresní úlohu [3].



Obrázek 1.7.: Základní princip detekce modelu YOLO využívající rozdělení obrazu do mřížky (převzato z [3, s. 2])

Jak ukazuje obrázek 1.7, vstupní obraz je nejprve virtuálně rozdělen do mřížky $S \times S$. Pokud střed hledaného objektu spadne geometricky do konkrétní buňky této mřížky, stává se tato konkrétní buňka plně zodpovědnou za jeho detekci. Každá buňka následně predikuje fixní počet B ohraničujících obdélníků, míru spolehlivosti (z angl. *confidence score*) pro tyto obdélníky a pravděpodobnosti zařazení do C různých tříd. Celkový výstup sítě je tak elegantně zakódován do jediného tenzoru o rozměrech $S \times S \times (B \cdot 5 + C)$.



Obrázek 1.8.: Vnitřní architektura modelu YOLO znázorňující sekvenci konvolučních a plně propojených vrstev (převzato z [3, s. 3])

Na obrázku 1.8 je detailně znázorněna topologie vrstev původního modelu YOLO, jejíž architektura byla přímo inspirována modelem GoogLeNet[2]. Systém na svém vstupu přijímá obraz o přesném rozlišení 448×448 pixelů. Samotná síť se skládá z 24 konvolučních vrstev, které slouží k postupné a hluboké extrakci vizuálních příznaků z obrazu (od jednoduchých hran až po komplexní tvary vozidel). Za nimi následují 2 plně propojené vrstvy (z angl. *fully connected layers*), jež získané příznaky agregují a generují finální predikční tenzor o rozměrech $7 \times 7 \times 30$.

Klíčovým inovačním prvkem této architektury je zařazení střídavých redukčních konvolučních vrstev s filtrem 1×1. Tyto vrstvy fungují jako informační úzká hrdla (z angl. *bottlenecks*) – efektivně zmenšují prostor příznaků z předchozích vrstev, čímž drasticky redukují množství potřebných matematických operací bez zásadní ztráty kontextu. Moderní varianty modelů z rodiny YOLO jsou pro účely přesné objektové detekce standardně trénovány a vyhodnocovány na rozsáhlém datasetu COCO[3] (z angl. *Common Objects in Context*) [7]. Tento dataset obsahuje stovky tisíc detailně anotovaných snímků reálných scén a plně definuje 80 základních tříd objektů, což detekčnímu modelu poskytuje vysoce robustní výchozí základ pro spolehlivé rozpoznávání různorodých účastníků dopravního provozu (osobní automobily, autobusy, nákladní vozy či chodce).

[2]GoogLeNet (známý také pod označením Inception v1) je průlomová architektura hluboké konvoluční neuronové sítě od společnosti Google, která v roce 2014 zvítězila v prestižní soutěži počítačového vidění ImageNet (ILSVRC). Vyznačuje se velmi vysokou výpočetní efektivitou.

[3]COCO dataset

1.4. Systémy pro monitorování dopravy

Monitorování dopravy představuje klíčovou součást moderních inteligentních dopravních systémů. Jeho primárním cílem je kontinuální získávání informací o dopravním provozu, jako je intenzita dopravy, průměrná rychlost vozidel, detekce kongescí nebo výskyt nestandardních dopravních událostí. Tyto agregované informace jsou následně využívány pro aktivní řízení dopravy, strategické plánování městské infrastruktury a zvyšování celkové bezpečnosti silničního provozu [2].

Tradiční metody dopravního monitoringu

Tradiční metody monitorování dopravy jsou historicky založeny převážně na fyzických kontaktních senzorech nebo manuálním sběru dat. Mezi jejich hlavní výhody patří relativně přímočará implementace a dlouhodobé ověření v praxi, zásadní nevýhodou je však jejich omezená flexibilita, neschopnost poskytovat hlubší kontext a vysoké náklady na instalaci i následnou údržbu.

Jednou z nejstarších metod je manuální sčítání dopravy, při kterém jsou dopravní prostředky zaznamenávány lidským pozorovatelem. Tento přístup je extrémně časově i personálně náročný, náchylný k lidským chybám způsobeným únavou a je naprosto nevhodný pro kontinuální dlouhodobý monitoring dopravního provozu [2].

Další široce rozšířenou technologií jsou indukční smyčky zabudované přímo do povrchu vozovky, které detekují přítomnost kovového podvozku vozidla na základě změny elektromagnetického pole. Ačkoliv poskytují relativně spolehlivá data o prostých průjezdech vozidel, jejich instalace vyžaduje destruktivní zásah do vozovky, což omezuje dopravu. Samotné smyčky navíc podléhají rychlému opotřebení vlivem zátěže a povětrnostních podmínek. [2].

Pro monitorování rychlosti a vzdálenosti jsou rovněž hojně využívány radarové a lidarové senzory. Tyto technologie dosahují vysoké přesnosti i za zhoršené viditelnosti, avšak jejich nevýhodou jsou vysoké pořizovací náklady a omezené možnosti vizuální klasifikace jednotlivých typů objektů (např. obtížné rozlišení mezi malým motocyklem a chodcem) [2].

Moderní kamerové systémy

S raketovým rozvojem počítačového vidění a dostupností vysokého výpočetního výkonu se v dopravní infrastruktuře stále častěji prosazují kamerové systémy založené na analýze obrazových dat. Na rozdíl od jednorozměrných dat z indukčních smyček umožňují kamerové systémy získávat z jednoho zařízení bohaté, vícerozměrné informace o celé dopravní scéně, včetně přesného typu vozidel, jejich trajektorií nebo anomálního chování účastníků provozu [1].

Mezi hlavní výhody těchto systémů patří vysoká flexibilita (změna sledované oblasti často vyžaduje pouze softwarovou úpravu virtuálních čar, nikoliv překopání vozovky) a možnost využití jedné kamery pro paralelní běh více analytických úloh. Nevýhodou kamerových systémů jsou

naopak jejich limity spojené s kvalitou vstupních obrazových dat. Výkon detekčních a sledovacích algoritmů může být negativně ovlivněn prudkými změnami světelných podmínek, nepříznivým počasím (mlha, hustý déšť) nebo vzájemným vizuálním překrýváním objektů ve scéně. Tyto faktory představují výzvu zejména v hustém městském provozu [2].

Vstupní zařízení kamerových systémů



Obrázek 1.9.: Typické umístění dohledových IP kamer na sloupu infrastruktury. Toto neinvazivní řešení poskytuje stabilní obrazový tok pro následnou detekci a inferenci na okrajových zařízeních (převzato z [8]).

Pro zajištění kvalitního obrazového vstupu, který je pro algoritmy počítačového vidění kritický, se v moderních Edge Artificial Intelligence (Umělá inteligence na okraji sítě / lokální zpracování modelů na koncových zařízeních) (Edge AI) systémech využívají primárně dva typy snímacích zařízení, jež přímo reflektují potřeby vývoje i reálného nasazení v dopravní infrastruktuře:

- **IP kamery:** Představují současný standard v budování chytrých měst. Tato zařízení nejenže snímají obraz, ale rovnou ho digitálně kódují a odesílají prostřednictvím počítačové sítě (nejčastěji pomocí protokolů RTSP nebo ONVIF). Jejich obrovskou výhodou je snadná integrace do existující síťové infrastruktury a možnost napájení přes jeden datový kabel (technologie PoE). Pro účely detekce na okrajových zařízeních poskytují IP kamery ideální a stabilní zdroj datového toku, ze kterého systém v reálném čase extrahuje jednotlivé snímky pro inferenci.
- **Kamerové moduly s přímým rozhraním (např. senzory Sony IMX):** Jedná se o kompaktní kamerové moduly navržené pro přímé hardwarové připojení k jednodeskovým počítačům (jako je platforma Raspberry Pi) pomocí vysokorychlostní sběrnice MIPI CSI. Zásadní výhodou tohoto řešení je minimální latence, jelikož surová obrazová data putují ze

snímače rovnou do operační paměti výpočetního zařízení bez nutnosti jakéhokoliv síťového kódování a dekódování. Tyto senzory představují vysoce efektivní nástroj pro prototypování a autonomní nasazení analytických uzlů bez nutnosti budování složité lokální sítě.

Existující řešení a projekty

V současnosti existuje na trhu řada komerčních i výzkumných řešení zaměřených na monitorování dopravy. Většinu těchto systémů lze z architektonického hlediska rozdělit na dvě hlavní větve: centralizovaná cloudová řešení a distribuovaná řešení na okrajích sítě (Edge AI).

Komerční platformy často spoléhají na to, že kamerové systémy na křižovatkách slouží pouze jako pasivní snímače, které odesílají nepřetržitý videostream do vzdálených cloudových datových center. Zde se za pomoci masivního výpočetního výkonu provádí přesná analytika a trasování. Ačkoliv je tento přístup vysoce přesný, naráží na limity v podobě vysokých nároků na propustnost síťového připojení, latenci a v neposlední řadě představuje bezpečnostní riziko z hlediska ochrany osobních údajů (GDPR), jelikož citlivé videozáznamy plynule opouštějí lokální infrastrukturu.

Moderním a stále preferovanějším trendem jsou proto systémy implementované přímo na okrajových zařízeních (z angl. *edge devices*). Zde je kladen důraz na efektivní využití úsporných výpočetních prostředků a AI akcelerátorů přímo v místě sběru dat [9].

1.5. Edge AI a vestavěné systémy

Koncept tzv. Edge AI označuje moderní architektonický přístup, při kterém jsou výpočetně náročné úlohy umělé inteligence realizovány přímo na okrajových zařízeních v těsné blízkosti zdroje dat, nikoliv v centrálním cloudovém prostředí. Tento přesun logiky umožňuje dramatické snížení latence, omezení objemu přenášených dat a mnohem efektivnější využití dostupných síťových zdrojů [9].

Požadavky na zpracování s nízkou latencí

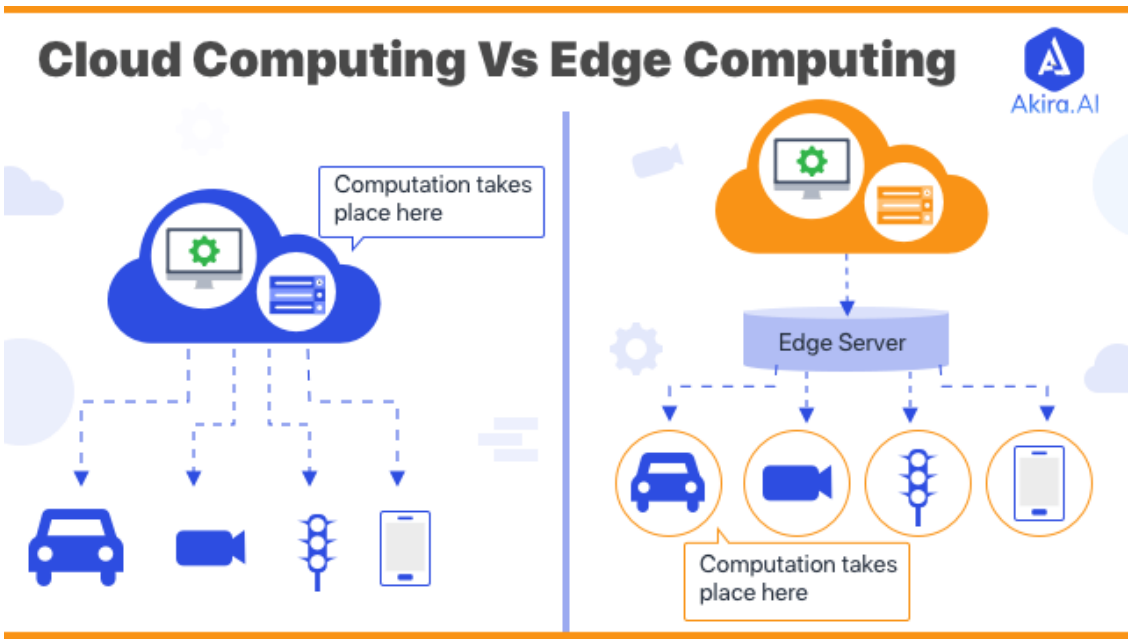
Při nasazení v reálné dopravní infrastruktuře je kladen extrémní důraz na rychlost vyhodnocování a efektivní využití dostupných hardwarových prostředků. Namísto obecného a často zavádějícího pojmu „reálný čas“ je v kontextu této práce definován přísný časový požadavek – navržený algoritmus musí dokázat kompletně zpracovat jeden snímek v čase kratším než 1/20 sekundy (což odpovídá zpracování do 50 ms, potažmo propustnosti 20 snímků za sekundu).

Tyto časové limity jsou kritické zejména u vestavěných systémů a okrajových zařízení (z angl. *edge devices*), jež nedisponují masivní výpočetní silou velkých datacenter. Splnění těchto limitů zaručuje, že nedojde ke ztrátě informací o rychle jedoucích vozidlech ani k nežádoucímu hromadění zpožděných dat ve vyrovnávacích pamětech [10].

Zpracování obrazu na okraji sítě

Zpracování obrazu na okraji sítě (z angl. *Edge Computing*) představuje přímou alternativu ke klasickému centralizovanému zpracování. V případě tradičního cloudového řešení musí být surová obrazová data (často tvořící masivní datový tok) neustále odesílána do vzdáleného datového centra. Naproti tomu edge přístup analyzuje video přímo na zařízení, ke kterému je kamera připojena.

Hlavním rozdílem a zároveň největším benefitem je eliminace zpoždění sítě (latence). Lokální inference hlubokých neuronových sítí přímo na okrajovém zařízení nejenže zajišťuje okamžitou odezvu, ale zároveň razantně zvyšuje celkovou robustnost systému. V případě dočasného výpadku internetového připojení může systém nadále plnohodnotně fungovat, lokálně ukládat agregovaná textová data o dopravě a odeslat je až po obnovení spojení [9].



Obrázek 1.10.: Porovnání architektury a datových toků u edge a cloudového zpracování (převzato z [11])

Na obrázku 1.10 je schematicky znázorněn rozdíl mezi oběma přístupy. Cloud computing se spoléhá na centrální servery, což vytváří úzké hrdlo na síťové vrstvě. Edge computing naopak přesouvá výpočetní logiku (inferenci) až na samotný okraj sítě k senzorům, což garantuje vysokou propustnost a okamžité vyhodnocování.

Hardwarové AI akcelerátory

AI akcelerátory, často označované jako NPU (z angl. *Neural Processing Unit (Neuronový procesor pro akceleraci umělé inteligence)*), jsou specializované integrované obvody navržené primárně pro efektivní provádění tenzorových výpočtů. Na rozdíl od univerzálních centrálních procesorů (CPU) jsou tyto čipy na hardwarové úrovni optimalizovány pro masivní paralelní zpracování maticových operací, jež tvoří matematický základ hlubokých konvolučních sítí.

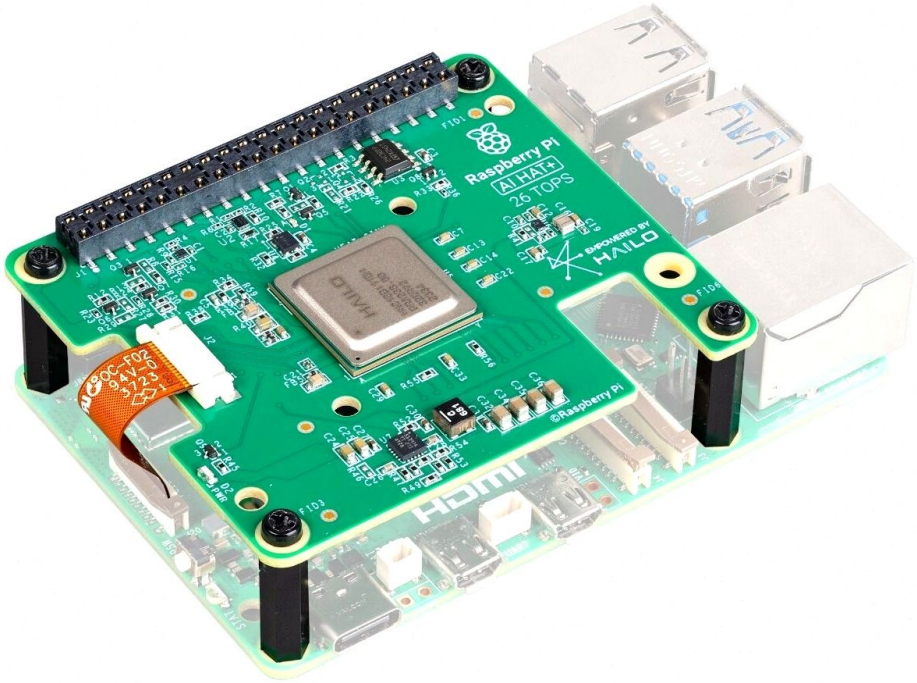
V kontextu Edge AI jsou tyto akcelerátory naprosto nezbytné, protože překonávají tzv. von Neumannovo úzké hrdlo. Běžné procesory ztrácejí obrovské množství času a energie neustálým přesouváním mezivýsledků mezi výpočetními jednotkami a hlavní pamětí. Akcelerátory tento problém eliminují tím, že udržují data co nejblíže samotným výpočetním jádrům. Umožňují tak nasazení složitých detekčních a sledovacích modelů na energeticky úsporných a prostorově omezených vestavěných zařízeních, a to při zachování propustnosti nutné pro plynulou analýzu dopravy bez závislosti na výkonných serverových farmách [10, 12].

Platforma Raspberry Pi a akcelerace pomocí Hailo-8

Platforma Raspberry Pi [4] představuje rodinu kompaktních jednodeskových počítačů (z angl. *Single-Board Computers*), které se staly standardem pro prototypování a vývoj vestavěných systémů. Její hlavní vlastností a výhodou je nízká pořizovací cena, obrovská komunitní podpora, stabilní operační systém (založený na linuxovém jádře) a především široká škála hardwarových rozhraní pro připojení periferních senzorů a modulů [13].

Zásadním omezením samotné architektury Raspberry Pi je však její hrubý výpočetní výkon. Integrovaný procesor postavený na architektuře ARM není schopen v reálném čase zpracovávat náročné úlohy počítačového vidění, a už vůbec ne zajišťovat běh hlubokých neuronových sítí. Z tohoto důvodu je pro nasazení v systémech monitorování dopravy nezbytné doplnit základní desku o externí výpočetní modul [14].

[4] Rpishop



Obrázek 1.11.: Rozšiřující modul Raspberry Pi AI HAT+ s integrovaným procesorem Hailo-8 (převzato z [15])

Řešením tohoto výpočetního omezení je využití specializovaných rozšiřujících desek, jako je modul Raspberry Pi AI HAT+ (znázorněný na obrázku 1.11). Srdcem tohoto modulu, připojeného přes rozhraní PCIe, je pokročilý AI procesor Hailo-8 od stejnojmenné izraelské společnosti, jež se specializuje na vývoj výkonných neurálních akcelerátorů.

Klíčovým parametrem tohoto akcelerátoru je deklarovaný výpočetní výkon 26 TOPS (z angl. *Tera Operations Per Second*). Předpona „Tera“ v matematickém vyjádření představuje hodnotu 10^{12}. Tento čip je tedy fyzicky schopen odbavit masivních 26×10^{12} (26 bilionů) operací za jedinou sekundu při inferenci modelu. To, jakým způsobem tohoto výkonu dosahuje, je však stejně důležité jako samotná číselná hodnota. Čipy Hailo využívají inovativní architekturu řízenou datovým tokem (z angl. *Structure-Defined Dataflow Architecture*). Zatímco tradiční GPU zpracovávají vrstvy neuronové sítě sekvenčně a neustále zapisují data do externí paměti, Hailo-8 mapuje celou topologii neuronové sítě přímo na své hardwarové zdroje. Obrazová data tak čipem protékají kontinuálně od jedné vrstvy ke druhé bez nutnosti přístupu k externí RAM.

Tato obrovská výpočetní propustnost spojená s extrémní energetickou účinností neposkytuje pouze dostatek výkonu pro plynulý běh pokročilých modelů rodiny YOLO. Systému dodává takovou kapacitní rezervu, že dokáže inferenci vysoce paralelizovat. V praxi to znamená, že systém může přijímat a vyhodnocovat obrazová data z několika nezávislých video streamů zcela

naráz (například synchronní analýza RTSP toků ze dvou různých IP kamer na křižovatce), aniž by došlo k degradaci počtu zpracovaných snímků za sekundu FPS [10, 12]. Tím se toto kompaktní hardwarové řešení stává vysoce škálovatelným nástrojem pro robustní a přesné sledování dopravy.

1.6. Metodika testování a evaluace

Vyhodnocení kvality systémů pro detekci, sledování a počítání objektů představuje nedílnou součást návrhu a implementace řešení založených na počítačovém vidění. Cílem evaluace je objektivně posoudit spolehlivost navrženého systému a identifikovat jeho limity. V oblasti dopravního monitorování je však důležité odlišit hodnocení samotného matematického modelu (zda správně detekuje obdélníky v izolovaném snímku) od hodnocení celého systému jako funkčního celku (zda spolehlivě počítá vozidla v čase) [1, 2].

Metodika vyhodnocení detekce v reálném prostředí

Pro vyhodnocení přesnosti rozpoznávání objektů nasazeným modelem YOLO v konkrétním kamerovém streamu se využívá metoda manuální obrazové analýzy vybraných referenčních snímků. Vzhledem k absenci předem připraveného a anotovaného datasetu pro danou lokaci jsou z videozáznamu extrahovány reprezentativní statické snímky (např. v různých světelných podmínkách či při různé hustotě provozu).

V těchto izolovaných snímcích je následně provedeno pečlivé manuální sečtení a označení všech reálně přítomných vozidel lidským pozorovatelem, čímž vzniká lokální referenční vzorek (*ground truth*). Výstup detekčního modelu na stejném snímku je s tímto vzorkem vizuálně porovnán, přičemž jsou pro každou třídu identifikovány a zaznamenány následující hodnoty:

- **True Positives (TP):** Správně detekovaná vozidla. Model označil ohraničujícím boxem vozidlo tam, kde se skutečně fyzicky nachází.
- **False Positives (FP):** Falešné detekce. Model označil za vozidlo něco, co ním není (např. stín, značku, sloup), případně vytvořil duplicitní překrývající se detekci pro jedno a to samé auto.
- **False Negatives (FN):** Nerozpoznaná vozidla. Vozidlo na snímku prokazatelně je, ale model jej vůbec nedetekoval.
- **True Negatives (TN):** Správně zamítnuté pozadí. Tento stav označuje prázdný prostor, který model správně ignoroval. V kontextu detekce objektů ohraničujícími boxy se však hodnota TN v praxi nepočítá.

Vztah mezi predikcí modelu a skutečností se ve strojovém učení standardně vizualizuje pomocí tzv. matice záměn (z angl. *Confusion Matrix*), která je pro přehlednost znázorněna v tabulce 1.1.

Predikce/Skutečnost	**Vozidlo je přítomno**	**Vozidlo není přítomno**
Model hlásí detekci	TP	FP
Model nehlásí detekci	FN	TN

Tabulka 1.1.: Základní matice záměn (Confusion Matrix).

Na základě těchto hodnot jsou následně vypočítány reálné metriky pro danou scénu. Tato analýza poskytuje kritický vhled do toho, do jaké míry případné chyby ve finálním sčítání pocházejí z nepřesné primární detekce a do jaké míry jsou způsobeny až selháním sledovacího algoritmu.

Metriky hodnocení detekčních modelů

Při samotném vývoji a trénování detekčních modelů se k objektivnímu měření výkonu na referenčních datasetech (tzv. *ground truth*) využívá standardizovaná sada matematických metrik [1]:

- **Precision (Přesnost):** Vyjadřuje podíl skutečně správných detekcí vůči všem detekcím, které model vyprodukoval. Indikuje, jak moc lze věřit modelu, když ohlásí nález vozidla.

$$Precision = \frac{TP}{TP + FP}$$

- **Recall (Úplnost):** Udává schopnost systému nalézt všechny relevantní objekty přítomné ve scéně. Definuje se jako podíl správně detekovaných objektů vůči reálnému počtu existujících objektů.

$$Recall = \frac{TP}{TP + FN}$$

- **IoU (Intersection over Union):** Vyjadřuje exaktní míru geometrického překryvu mezi predikovaným ohraničujícím boxem (B_{pred}) a reálným boxem (B_{gt}). Čím více se hodnota blíží k jedné, tím je lokalizace přesnější.

$$IoU = \frac{\text{Plocha průniku}}{\text{Plocha sjednocení}} = \frac{|B_{pred} \cap B_{gt}|}{|B_{pred} \cup B_{gt}|}$$

- **mAP (Mean Average Precision):** Představuje komplexní ukazatel výkonu modelu napříč všemi detekovanými třídami (N), který zohledňuje přesnost, úplnost i kvalitu lokalizace zjištěnou pomocí křivky Average Precision (AP).

$$mAP = \frac{1}{N} \sum_{i=1}^{N} AP_i$$

- **Accuracy (Přesnost klasifikace):** Metrika vyjadřující celkový podíl všech správných rozhodnutí. Jak již bylo zmíněno, v detekci objektů má vzhledem k obrovské nerovnováze

mezi počtem objektů a plochou prázdného pozadí (obrovské a nedefinovatelné množství TN) jen mizivou vypovídající hodnotu.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Vzhledem k tomu, že v rámci této bakalářské práce je implementován a nasazován již hotový předtrénovaný model z rodiny YOLO, není primárním cílem optimalizace jeho interních vah pomocí výše zmíněných metrik na testovacích datasetech. Cílem je naopak ověření jeho reálné propustnosti a praktické výkonnosti jakožto sčítacího softwarového uzlu v konkrétním dopravním prostředí.

Metodika vyhodnocení počítání v reálném prostředí

Vyhodnocení správnosti sčítání objektů je v dopravních aplikacích klíčové. Na rozdíl od detekce izolovaných snímků se zde hodnotí konzistence sledovacího algoritmu (např. zda udrží ID vozidla) a správná prostorová identifikace průjezdů vyhrazenými počítacími liniemi.

Hlavními zdroji chyb v reálném prostředí jsou časté vizuální překryvy objektů (okluze), ztráta identifikátoru způsobující opakované započítání téhož vozidla, nebo dynamické změny světelných podmínek a vrhání stínů. Jak potvrzují srovnávací studie zaměřené na reálné nasazení videodetekčních počítacích systémů, právě tyto faktory vnějšího prostředí představují největší výzvu pro udržení vysoké a stabilní provozní přesnosti [2], [16].

V reálném nasazení bez existence předem připravených exaktních datových sad je standardní evaluační metodou vytvoření vlastní sady referenčních dat (tzv. ground truth) formou nezávislého manuálního sčítání z pořízeného videozáznamu [17], [16]. Referenční hodnota je tak získána nezávislým pozorováním, čímž je stanoven skutečný počet průjezdů vozidel (N_{real}). Tento údaj je následně porovnán s počtem vozidel detekovaných automatizovaným systémem (N_{sys}) pomocí metriky poměrové přesnosti sčítání ($Accuracy_{count}$):

$$Accuracy_{count} = \left(1 - \frac{|N_{real} - N_{sys}|}{N_{real}}\right) \cdot 100\ [\%]$$

Tato metrika věrně a zcela exaktně reflektuje celkovou provozní úspěšnost systému při kontinuálním sčítání vozidel, a právě ona bude využita jako primární hodnoticí ukazatel v testovací části této práce.

1.7. Etické aspekty a GDPR

Při návrhu, nasazení a provozu jakýchkoliv kamerových systémů na veřejných prostranstvích a dopravních komunikacích je absolutně nezbytné zohlednit principy ochrany osobních údajů. Tyto povinnosti primárně vyplývají z platného Nařízení Evropského parlamentu a Rady (EU) 2016/679,

obecně známého pod zkratkou GDPR (z angl. *General Data Protection Regulation (Obecné nařízení o ochraně osobních údajů)*). Moderní kamerové systémy totiž ze své podstaty mohou neúmyslně zachytávat citlivé identifikační prvky, jakými jsou tváře chodců, řidičů nebo konkrétní registrační značky vozidel.

Navrhované řešení v rámci této bakalářské práce proto plně a striktně respektuje moderní přístup tzv. *Privacy by Design* (ochrana soukromí již od fáze samotného návrhu softwarové architektury). Tohoto principu je dosaženo právě díky integraci konceptu Edge AI. Veškeré algoritmické zpracování obrazových dat z kamery probíhá plně lokálně, přímo v operační paměti okrajového zařízení, které je umístěno bezprostředně u zdroje videa [9].

Díky lokální a okamžité inferenci se žádný surový obrazový signál, videozáznam ani snímky obsahující potenciální osobní údaje nikam neukládají, neodesílají se přes nezabezpečené sítě a nejsou nahrávány do žádného vzdáleného cloudového úložiště. Do databázového systému se propisují a k následné vizualizaci odesílají pouze finální, přísně anonymizovaná a agregovaná numerická metadata – například celkový typ objektu (automobil, chodec), hrubý časový údaj, směr jeho pohybu a identifikátor sčítací brány.

Tento architektonický přístup bezezbytku naplňuje zásadu minimalizace osobních údajů, která je jedním z nosných a nejdůležitějších pilířů legislativy GDPR. Systém tak poskytuje plnohodnotná statistická data pro analýzu dopravy, aniž by jakýmkoliv způsobem zasahoval do soukromí účastníků provozu.

2. Návrh systému

2.1. Požadavky na systém

Navrhovaný systém je určen pro automatizovanou analýzu silniční dopravy pomocí metod počítačového vidění. Cílem je detekce a sledování vozidel v reálném čase a následná extrakce statistických údajů o jejich průjezdech.

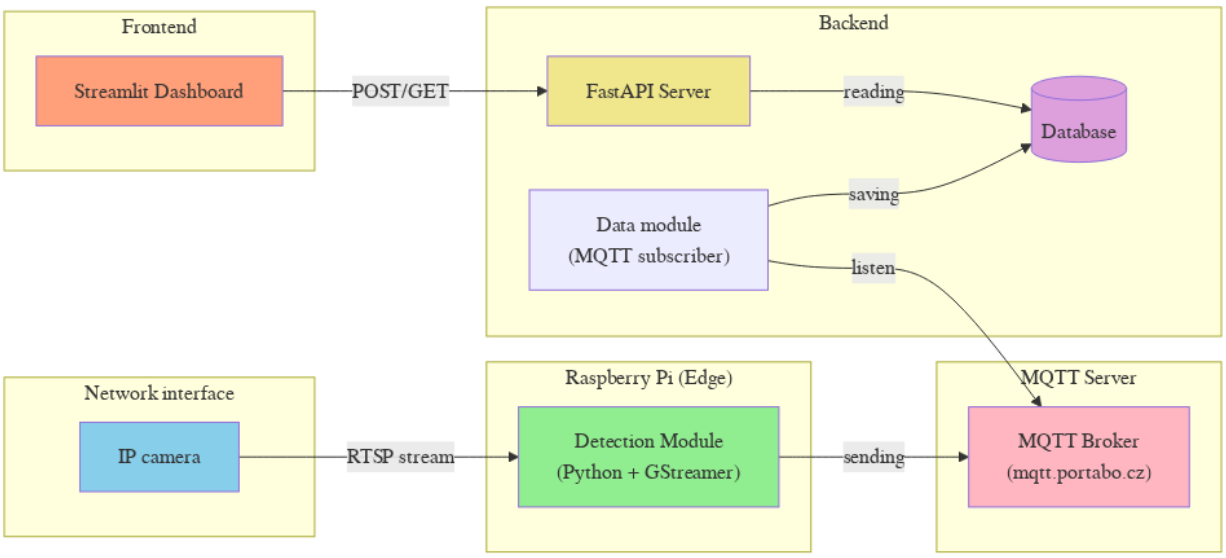
Mezi hlavní funkční požadavky patří:

- detekce vozidel v obrazové sekvenci,
- klasifikace detekovaných vozidel do kategorií,
- sledování klasifikovaných objektů napříč jednotlivými snímky,
- identifikace průjezdu klasifikovaných objektů definovanou detekční linií (ROI),
- ukládání detekčních událostí do databáze,
- vizualizace agregovaných statistik.

Systém musí být schopen provozu v reálném čase na vestavěném zařízení s omezenými výpočetními prostředky. Z tohoto důvodu je navržena architektura založená na principu *edge computing*, kdy je inference neuronové sítě prováděna přímo na zařízení v místě sběru dat [11].

2.2. Celková architektura a tok dat

Architektura systému je navržena jako vícevrstvá, distribuovaná a modulární. Jednotlivé komponenty jsou odděleny podle své funkce a komunikují spolu asynchronně prostřednictvím lehkého zprávového protokolu MQTT [18]. Toto rozdělení umožňuje lepší škálovatelnost, robustnost a minimalizaci vzájemné závislosti komponent, což plně odpovídá moderním architekturám dopravních monitorovacích systémů založených na počítačovém vidění [2].



Obrázek 2.1.: Navržená architektura systému pro analýzu dopravy

Na obrázku 2.1 je znázorněna celková topologie navrženého řešení. Systém je rozdělen do pěti funkčních vrstev, kterými postupně prochází tok dat:

1. **Vrstva akvizice obrazu (Síťová vrstva):** Koncová IP kamera poskytuje kontinuální video stream přenášený po lokální síti pomocí protokolu RTSP.
2. **Vrstva zpracování videa (Edge vrstva):** Zde se provádí detekce, klasifikace a sledování objektů pomocí AI modulu. Obrazová data jsou přijata na okrajovém zařízení, předzpracována a předána detekčnímu modelu typu YOLO [3], který provádí detekci a klasifikaci objektů. Následný sledovací algoritmus (např. na principu SORT [4]) přiřazuje jednotlivým objektům unikátní identifikátory a vyhodnocuje jejich průchod přes virtuální detekční linii [17].
3. **Komunikační vrstva:** Vygenerované strukturované události o průjezdech jsou asynchronně odesílány prostřednictvím MQTT brokeru [18] do datové vrstvy.
4. **Datová a backendová vrstva:** Zajišťuje trvalé ukládání přijatých událostí do relační databáze a poskytuje aplikační rozhraní (REST API) pro přístup k těmto datům.
5. **Aplikační a vizualizační vrstva (Frontend):** Komunikuje s backendem pomocí REST API a zprostředkovává agregované statistické přehledy koncovému uživateli.

Oddělení jednotlivých kroků do samostatných vrstev umožňuje vysokou modularitu systému a minimalizaci vzájemné závislosti komponent.

2.3. Výběr hardwaru

Pro zajištění spolehlivého chodu celého řešení je hardwarová část fyzicky rozdělena na prvek pro sběr obrazových dat a výpočetní uzel pro jejich zpracování.

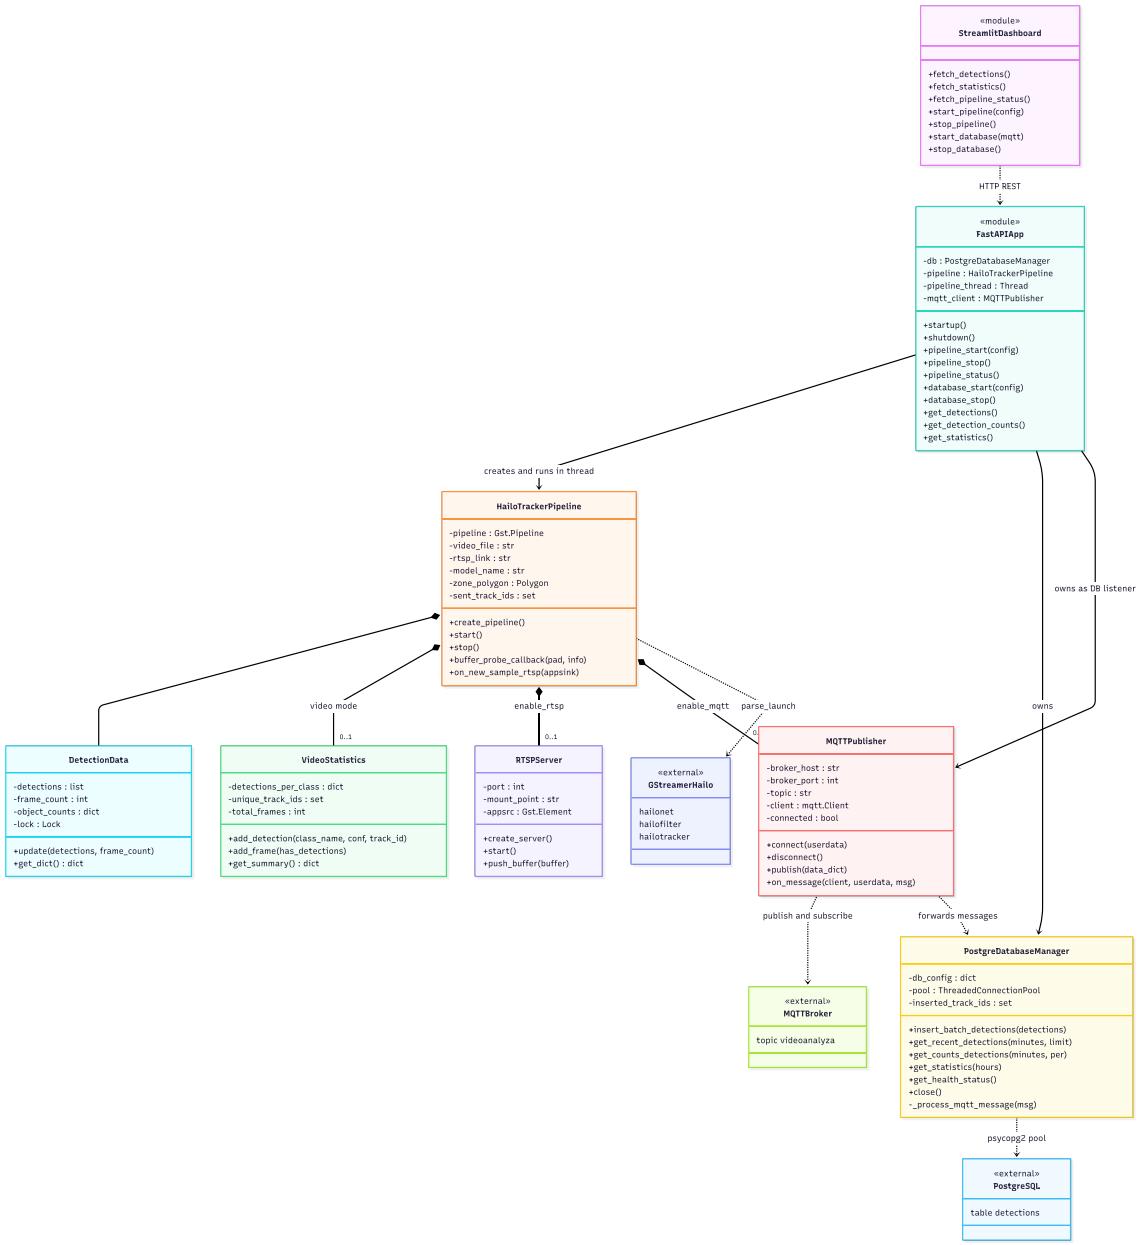
Kamerový systém: Pro dosažení dostatečné kvality detekce je využita IP kamera značky Hikvision, která umožňuje síťový přenos video streamu prostřednictvím protokolů RTSP nebo HTTP (z angl. *Hypertext Transfer Protocol (Hypertextový přenosový protokol)*). Použití IP kamery dovoluje flexibilní umístění zařízení mimo samotný výpočetní uzel a současně poskytuje vyšší odolnost vůči povětrnostním podmínkám v porovnání s běžnými kamerovými moduly pro vestavěná zařízení.

Zpracovatelská jednotka: Jako výpočetní platforma na hraně sítě (edge zařízení), která přijímá datový tok z lokální sítě, je navrženo zařízení Raspberry Pi 5. Tato platforma představuje vhodný kompromis mezi výkonem, spotřebou a pořizovací cenou [13]. Pro zajištění real-time inference neuronové sítě je doplněna o dedikovaný AI akcelerátor Hailo-8 kompatibilní s touto platformou [14]. Tento přístup umožňuje efektivní zpracování obrazu přímo na místě bez nutnosti využití cloudových služeb.

2.4. Návrh softwarových modulů

Objektový návrh aplikace (UML)

Pro zajištění modularity, snadné testovatelnosti a budoucí rozšiřitelnosti byl softwarový kód systému navržen s využitím objektově orientovaného programování (OOP). Jednotlivé funkční celky od zpracování videa přes mezivrstvu pro přenos zpráv až po databázové operace a aplikační rozhraní, jsou zapouzdřeny do samostatných tříd a modulů (viz obrázek 2.2). Tento přístup umožňuje provozovat detekční část zcela autonomně z příkazové řádky, nebo ji dynamicky řídit prostřednictvím webového rozhraní.



Obrázek 2.2.: UML diagram tříd navrženého dopravního monitorovacího systému.

Struktura softwarové aplikace se skládá z následujících klíčových tříd a modulů:

- **`HailoTrackerPipeline`** – Ústřední třída detekčního modulu na hraně sítě. Zapouzdřuje sestavení a řízení multimediálního řetězce (`Gst.Pipeline`), komunikaci s akcelerátorem Hailo-8 a registraci zpětného volání (`buffer_probe_callback`). Současně udržuje geometrickou definici oblasti zájmu (`zone_polygon`) a množinu již odeslaných identifikátorů (`sent_track_ids`) pro eliminaci duplicit.
- **`DetectionData`** – Datová struktura zajišťující vláknově bezpečné (*thread-safe*) uchovávání aktuálních výsledků detekce a počtů objektů pomocí synchronizačního zámku (`Lock`). Poskytuje metody pro serializaci dat do slovníku a generování překryvného textu do obrazu.
- **`VideoStatistics`** a **`RTSPServer`** – Volitelné (kompozičně vázané) pomocné třídy. `VideoStatistics` slouží k agregaci souhrnných metrik při zpracování video souborů, zatímco `RTSPServer`

umožňuje prostřednictvím prvku `appsrc` přeposílat zpracovaný video stream s vykreslenými detekcemi dále do sítě.

- **`MQTTPublisher`** – Univerzální komunikační třída zapouzdřující klienta protokolu MQTT. V architektuře plní dvojí roli: na straně detekční pipeline zajišťuje publikaci dat (`publish`) do tématu `videoanalyza`, zatímco na straně serveru funguje jako odběratel (*listener*), který přijaté zprávy předává metodě `on_message` ke zpracování do databáze.
- **`PostgreDatabaseManager`** – Třída zodpovědná za perzistenci a čtení dat z relační databáze PostgreSQL. Využívá fond spojení (`ThreadedConnectionPool`) z knihovny `psycopg2`, zpracovává příchozí MQTT zprávy, provádí dávkové vkládání záznamů (`insert_batch_detections`) a poskytuje agregační metody pro analytické dotazy.
- **`FastAPIApp`** a **`StreamlitDashboard`** – Aplikační a prezentační moduly. Modul `FastAPIApp` poskytuje REST API rozhraní pro čtení statistik z databáze a zároveň umožňuje vzdáleně spouštět a zastavovat detekční pipeline v samostatném vlákně (`Thread`). Modul `StreamlitDashboard` s tímto rozhraním komunikuje přes protokol HTTP a zajišťuje interaktivní vizualizaci dat pro koncového uživatele.

Detekční modul a logika počítání (ROI)

Detekční modul je založen na konvoluční neuronové síti typu YOLO, která umožňuje rychlou lokalizaci a klasifikaci objektů v obraze [3]. Pro následné sledování těchto objektů napříč snímky je navržen algoritmus typu SORT [4], případně jeho rozšířená varianta DeepSORT [6]. Každému sledovanému objektu je tak přiřazen unikátní identifikátor (ID), jenž je udržován po celou dobu jeho výskytu ve scéně.

Logika detekční zóny (ROI): Pro účely filtrace a počítání relevantních vozidel je v obraze definována virtuální oblast zájmu (tzv. *Region of Interest* - ROI) ve tvaru obecného polygonu [17]. Polygonální reprezentace umožňuje přesně vymezit sledovaný jízdní pruh a odfiltrovat nežádoucí detekce mimo komunikaci. Započítání vozidla proběhne v okamžiku, kdy se geometrický střed jeho ohraničujícího rámečku (*bounding box*) ocitne uvnitř definovaného polygonu. Aby nedocházelo k vícenásobnému započítání téhož vozidla v kolejnych snímcích, systém udržuje evidenci již zpracovaných identifikátorů `track_id` a každé vozidlo odešle ke zpracování pouze jednou.

Ukládání dat, databázové schéma a vizualizace

Strukturované detekční události jsou ukládány do relační databáze PostgreSQL, jež umožňují spolehlivé uchování dat a jejich následné statistické vyhodnocení [19]. Pro účely trvalé evidence byla navržena primární tabulka `detections`, jejíž struktura je popsána v tabulce 2.3. Každý zaznamenaný průjezd vozidla přes detekční linii vygeneruje právě jeden záznam.

Datový model

Datový model je založen na hlavní entitě *detections* (znázorněné na obrázku 2.3), která uchovává informace o jednotlivých detekcích a průjezdech vozidel. Struktura tabulky je navržena s ohledem na vysoký objem dat a efektivní časové dotazování.



Obrázek 2.3.: ER diagram databázového modelu.

Popis atributů tabulky detections:

- **id (BIGSERIAL)** – Primární klíč tabulky. Automaticky generovaná unikátní hodnota sloužící k jednoznačné identifikaci každé detekce. Typ *BIGSERIAL* byl zvolen s ohledem na předpokládaný vysoký objem záznamů.
- **timestamp_ (TIMESTAMPTZ)** – Čas detekce objektu. Datový typ *TIMESTAMPTZ* umožňuje ukládání časové informace včetně časové zóny, což je důležité pro přesnou časovou analýzu dopravních událostí.
- **frame_id (INTEGER)** – Identifikátor snímku, ve kterém byla detekce provedena. Umožňuje zpětné dohledání konkrétního snímku v případě analýzy nebo ladění systému.
- **class_name (TEXT)** – Název detekované třídy objektu (např. *car*, *truck*, *bus*). Tento atribut umožňuje následnou agregaci a statistické vyhodnocení podle typu vozidla.
- **confidence (REAL)** – Pravděpodobnost detekce generovaná neuronovou sítí. Je definováno omezení `CHECK (confidence >= 0 AND confidence <= 1)`, které zajišťuje validitu ukládaných hodnot.

- **x1, y1, x2, y2 (FLOAT)** – Souřadnice ohraničujícího obdélníku (*bounding box*) detekovaného objektu. Hodnoty představují levý horní a pravý dolní roh objektu v rámci zpracovávaného obrazu. Integritní omezení `CHECK (x2 > x1 AND y2 > y1)` zajišťuje geometrickou konzistenci dat.
- **track_id (INT)** – Identifikátor sledovaného objektu, generovaný sledovacím algoritmem. Umožňuje sledování pohybu konkrétního vozidla napříč více snímky.
- **model_name (TEXT)** – Označení použitého detekčního modelu (např. *yolov8s*). Sloupec je navržen pro potřeby budoucího porovnávání úspěšnosti různých verzí neuronových sítí nad reálnými daty.
- **device_name (TEXT)** – Identifikátor konkrétní výpočetní jednotky (edge zařízení) nebo kamery. Zajišťuje připravenost databázového schématu na horizontální škálování systému do více lokalit.

Indexování: S ohledem na charakter dotazů byly vytvořeny indexy nad atributy *timestamp_*, *class_name* a *track_id*. Tyto indexy optimalizují zejména dotazy na poslední detekce, časově omezené statistiky, filtrování podle typu vozidla a analýzu pohybu konkrétního objektu. Použití sestupného indexu nad atributem *timestamp_* umožňuje efektivní získávání nejnovějších detekcí, což je častý scénář v reálném provozu systému.

Analýza a vizualizace dat

Backendová vrstva zpřístupňuje uložená data prostřednictvím REST API postaveného na moderním frameworku FastAPI. Pro následné numerické transformace a časové agregace záznamů systém využívá knihovny NumPy [20] a Pandas [21]. Koncové webové rozhraní s interaktivními grafy je navrženo s využitím frameworku Streamlit v kombinaci s grafickou knihovnou Plotly [22], což umožňuje interaktivní zobrazení časových řad, histogramů a agregovaných statistik dopravního provozu.

Technologie

Celkový přehled zvolených technologií pro jednotlivé vrstvy navržené architektury shrnuje tabulka 2.1.

Komponenta systému	**Zvolená technologie**
Operační systém (Edge)	Raspberry Pi OS (Debian Linux)
Programovací jazyk	Python 3.11
Zpracování videa	GStreamer
AI inference a sledování	HailoRT + TAPPAS (YOLO)
Komunikační protokol	MQTT
Databázové úložiště	PostgreSQL + Psycopg
Backend a REST API	FastAPI + Pandas / NumPy
Vizualizační frontend	Streamlit + Plotly

Tabulka 2.1.: Přehled technologického stacku navrženého systému.

3. Implementace systému

3.1. Konfigurace prostředí a automatizace běhu

Pro praktickou realizaci systému na cílové platformě Raspberry Pi 5 byl nainstalován operační systém Raspberry Pi OS (založený na distribuci Debian Linux) [13], který poskytuje plnou podporu hardwarových rozhraní, dostupnost potřebných knihoven pro práci s obrazem a sítí a kompatibilitu s ovladači AI akcelerátoru Hailo-8. Řídicí skripty byly implementovány v jazyce Python 3.11 [23].

Automatická instalace závislostí a spouštění služeb

Pro zajištění plné reprodukovatelnosti prostředí a snadného nasazení na nové zařízení byl vytvořen instalační skript, který automatizuje přípravu celého systému. Tento skript provádí:

- instalaci systémových balíčků a multimediálního frameworku GStreamer,
- instalaci běhového prostředí HailoRT a knihoven TAPPAS [24] pro AI akcelerátor,
- vytvoření virtuálního prostředí a instalaci Python knihoven (Ultralytics, Shapely, Paho-MQTT, Psycopg, FastAPI, Streamlit, Pandas, Plotly),
- nastavení systémových oprávnění a proměnných prostředí.

Aby byl zajištěn plně autonomní provoz systému v reálných podmínkách (např. při výpadku napájení a následném restartu zařízení), byl v operačním systému nakonfigurován spouštěcí mechanismus automatického spuštění hlavních služeb. Po inicializaci operačního systému spouštěcí skript nastaví potřebné proměnné prostředí a ve správném pořadí automaticky odstartuje hlavní komponenty:

1. detekční pipeline běžící na edge zařízení,
2. odběratelskou službu (MQTT subscriber) zajišťující zápis do databáze,
3. backendový server (FastAPI) a webové vizualizační rozhraní (Streamlit).

Tento přístup umožňuje plně autonomní provoz zařízení bez nutnosti manuálního zásahu po restartu systému.

3.2. Příprava a kompilace detekčního modelu

Volba varianty modelu a předzpracování

V rámci implementace nebyl model trénován od začátku, ale byl využit předtrénovaný model rodiny YOLOv8 natrénovaný na datasetu COCO [7]. Během vývoje byly experimentálně zkompilovány a otestovány varianty YOLOv8n, YOLOv8s a YOLOv8m, které se liší počtem parametrů. Pro finální nasazení byla zvolena varianta **YOLOv8m**, jež na cílové platformě vykazovala optimální kompromis mezi rychlostí inference a přesností detekce vzdálenějších vozidel.

Pro nasazení modelu na akcelerátor Hailo-8 lze buď využít předpřipravené modely z repozitáře Hailo RPi5 Examples [25], nebo provést vlastní kompilaci do binárního formátu HEF (*Hailo Executable Format*) pomocí nástroje Hailo Dataflow Compiler (DFC) [26]. V této práci byl realizován kompletní proces vlastní kompilace. Před samotnou inferencí jsou vstupní snímky vždy převzorkovány na rozlišení 640×640 pixelů a převedeny do barevného formátu RGB.

Export modelu do formátu ONNX

Prvním krokem přípravy pro kompilátor Hailo DFC je převod vah modelu z nativního formátu PyTorch (`.pt`) do standardizovaného meziformátu ONNX (*Open Neural Network Exchange*). Export byl proveden pomocí knihovny Ultralytics s pevně definovanou velikostí vstupu a zjednodušením výpočetního grafu (ukázka 3.1).

Listing 3.1: Export modelu YOLOv8m do formátu ONNX.

```
from ultralytics import YOLO

model = YOLO("yolov8m.pt")

model.export(
    format="onnx",
    imgsz=640,
    opset=11,
    simplify=True
)
```

Výsledkem tohoto kroku je soubor `yolov8m.onnx`, který slouží jako přímý vstup pro optimalizační nástroje Hailo.

Kvantizace a kompilace do formátu HEF

Převod ONNX modelu do spustitelného formátu HEF byl proveden pomocí nástroje `hailomz` z knihovny Hailo Model Zoo [27]. Tento proces zahrnuje čtyři fáze:

1. překlad (parsing) ONNX grafu do meziformátu HAR (*Hailo Archive*),
2. optimalizaci a kvantizaci vah z 32bitové plovoucí řádové čárky (FP32) na 8bitová celá čísla (INT8),
3. alokaci hardwarových výpočetních zdrojů cílového čipu,
4. generování finálního binárního souboru HEF.

Pro správné provedení post-tréninkové kvantizace (PTQ) do formátu INT8 vyžaduje kompilátor kalibrační sadu čítající řádově stovky až tisíce snímků, na kterých analyzuje statistické rozložení aktivací v jednotlivých vrstvách. Pro tento účel byla využita validační část datasetu COCO (`val2017`) obsahující 5 000 snímků [7]. Vzhledem k vysoké výpočetní a paměťové náročnosti procesu kompilace (který trvá v řádu desítek minut) probíhal tento krok na externí pracovní stanici pomocí příkazu uvedeného v ukázce 3.2.

Listing 3.2: Kompilace modelu YOLOv8m pomocí nástroje Hailo Model Zoo.

```
hailomz compile yolov8m \
    --hw-arch hailo8 \
    --calib-path ./coco_val2017 \
    --classes 80
```

Vygenerovaný soubor `yolov8m.hef`, který je určen pro běh na architektuře Hailo-8, byl následně přenesen na zařízení Raspberry Pi 5, kde umožňuje provádět inferenci s výrazně nižší latencí a spotřebou energie při zachování vysoké detekční přesnosti.

3.3. Implementace zpracování videa a detekce

Konstrukce GStreamer pipeline

Zpracování obrazového toku v reálném čase je postaveno na zřetězení zásuvných modulů frameworku GStreamer. Pipeline se připojuje k IP kameře přes protokol RTSP, provádí hardwarově či softwarově akcelerované dekódování komprimovaného formátu H.264, škáluje obraz na rozlišení 640×640 pixelů a předává jej specializovaným prvkům Hailo (ukázka 3.3).

Listing 3.3: Zjednodušená konstrukce GStreamer pipeline.

```
pipeline_str = (
    "rtspsrc location=rtsp://CAMERA_IP latency=150 "
    "! rtph264depay ! h264parse ! avdec_h264 "
    "! videoconvert ! videoscale "
    "! video/x-raw,width=640,height=640,format=RGB "
    "! hailonet hef-path=yolov8m.hef batch-size=1 "
    "nms-score-threshold=0.6 nms-iou-threshold=0.5 "
    "! hailofilter function-name=yolov8m "
```

```
    "! hailotracker iou-thr=0.5 "
    "! videoconvert ! fakesink"
)
```

Samotnou inferenci na akcelerátoru zajišťuje prvek `hailonet`. Parametr `batch-size=1` garantuje, že každý přijatý snímek je zpracován okamžitě bez čekání na naplnění dávky více snímků, což minimalizuje latenci. Parametry `nms-score-threshold` a `nms-iou-threshold` konfigurují algoritmus *Non-Maximum Suppression* (NMS), jenž filtruje detekce s nízkou spolehlivostí a odstraňuje vícenásobné překrývající se rámečky nad stejným vozidlem. Následující prvek `hailofilter` provádí post-processing tenzorů a modul `hailotracker` přiřazuje objektům sledovací identifikátory na základě překryvu (`iou-thr=0.5`).

Pro účely ladění nebo paralelního ukládání záznamu lze pipeline na konci rozvětvit pomocí prvku `tee`, který duplikuje datový tok do více nezávislých větví a tím umožňuje paralelní zpracování výstupu z pipeline, např. pro současné streamování a ukládání videa. (ukázka 3.4).

Listing 3.4: Větvení výstupu pipeline pomocí prvku tee.

```
pipeline_str += "! tee name=t "
pipeline_str += (
    "t. ! queue ! appsink name=rtsp_sink "
    "t. ! queue ! x264enc ! mp4mux ! filesink location=output.mp4"
)
```

Aby nedocházelo k zahlcení paměti a postupnému narůstání zpoždění při případném kolísání výpočetního výkonu, jsou mezi klíčové fáze pipeline vloženy vyrovnávací fronty (`queue`), které oddělují jednotlivé fáze zpracování do samostatných vláken, s aktivovaným režimem `leaky=downstream`. V případě přetížení fronta automaticky zahodí nejstarší nezpracované snímky a upřednostní aktuální obraz z kamery.

Extrakce metadat pomocí Buffer Probe

Aby nebylo nutné převádět celé obrazové snímky z GStreameru do paměti Pythonu, je pro čtení výsledků detekce využit mechanismus *buffer probe*. Na zdrojový výstup (`src` pad) prvku `hailotracker` je zaregistrována zpětná volací funkce (*callback*), jež se automaticky spustí při průchodu každého snímku (ukázka 3.5).

Listing 3.5: Registrace buffer probe na výstupu sledovacího modulu.

```
hailotracker = self.pipeline.get_by_name('hailotracker')
pad = hailotracker.get_static_pad('src')
pad.add_probe(Gst.PadProbeType.BUFFER, self.buffer_probe_callback)
```

Uvnitř callback funkce jsou pomocí Hailo API přímo z paměťového bufferu GStreameru extrahovány objekty typu `HAILO_DETECTION`, které nesou informaci o detekované třídě, míře spolehlivosti, souřadnicích ohraničujícího obdélníku a přiděleném identifikátoru sledování (ukázka 3.6).

Listing 3.6: Extrakce detekčních metadat z GStreamer bufferu.

```
buffer = info.get_buffer()
roi = get_roi_from_buffer(buffer)
hailo_detections = roi.get_objects_typed(HAILO_DETECTION)

for detection in hailo_detections:
    label = detection.get_label()
    confidence = detection.get_confidence()
```

Filtrace v polygonální zóně (ROI) a eliminace duplicit

Pro každé detekované vozidlo je nejprve vypočítán geometrický střed jeho ohraničujícího rámečku (c_x, c_y). Pomocí geometrické knihovny `Shapely` je následně testováno, zda se tento bod nachází uvnitř uživatelsky definovaného polygonu oblasti zájmu (ukázka 3.7).

Listing 3.7: Filtrace detekcí v definované polygonální ROI zóně.

```
# Bounding box center determination
cx = bbox.xmin() + bbox.width() * 0.5
cy = bbox.ymin() + bbox.height() * 0.5

# Check if object is in zone
detection_point = Point(cx, cy)
if not self.zone_polygon.contains(detection_point):
    continue
```

Vzhledem k tomu, že vozidlo projíždějící zónou ROI je zachyceno na desítkách po sobě jdoucích snímků, je nezbytné zabránit jeho opakovanému započítání. Aplikace si proto udržuje množinu již odeslaných identifikátorů `sent_track_ids`. Pokud se dané `tracking_id` v množině již nachází, je detekce přeskočena (ukázka 3.8).

Listing 3.8: Prevence duplicitního odeslání téhož vozidla.

```
if tracking_id in self.sent_track_ids:
    continue

self._mark_sent(tracking_id)
```

Jelikož callback funkce GStreameru běží v samostatném vlákně, je aktualizace sdílených stavových proměnných aplikace chráněna synchronizačním zámkem (`Lock`), čímž je zajištěna vláknová bezpečnost (*thread-safety*):

Listing 3.9: Vláknově bezpečná aktualizace detekčních dat.

```
with self.lock:
```

```
    self.detections = detections
    self.frame_count = frame_count
    self.timestamp = datetime.now().isoformat()
```

Měření propustnosti (FPS)

Pro průběžné sledování výkonnosti pipeline je přímo v callback funkci implementován výpočet snímkové frekvence FPS podle vztahu:

$$\text{FPS} = \frac{N_{\text{frames}}}{t}$$

kde N_{frames} představuje celkový počet zpracovaných snímků od spuštění měření a t je uplynulý čas v sekundách (ukázka 3.10).

Listing 3.10: Průběžný výpočet FPS během běhu pipeline.

```
self.frame_count += 1
elapsed_time = time.time() - self.start_time
fps = self.frame_count / elapsed_time
```

3.4. Komunikace, ukládání a vizualizace dat

Publikace událostí přes MQTT

Nově zaznamenané průjezdy vozidel zónou ROI jsou zformátovány do podoby slovníku, který obsahuje identifikátor a název třídy, míru spolehlivosti, souřadnice rámečku, sledovací ID a časové razítko. Pokud seznam obsahuje nové události a spojení s MQTT brokerem je aktivní, data jsou serializována do formátu JSON a publikována do příslušného tématu (ukázka 3.11).

Listing 3.11: Sestavení a publikace detekčních událostí přes MQTT.

```
detection_dict = {
    "class_id": class_id,
    "class_name": label,
    "confidence": float(confidence),
    "bbox": bbox_coords,
    "track_id": tracking_id,
    "timestamp": current_timestamp
}

detection_list.append(detection_dict)

if detection_list and self.mqtt_publisher.connected:
```

```
    self.mqtt_publisher.publish(detection_list)
```

Identifikátor `track_id` je označen jako zpracovaný až v okamžiku úspěšného předání zprávy komunikačnímu modulu, což zaručuje, že při případném krátkodobém výpadku spojení nedojde ke ztrátě detekce.

Dávkové ukládání do databáze PostgreSQL

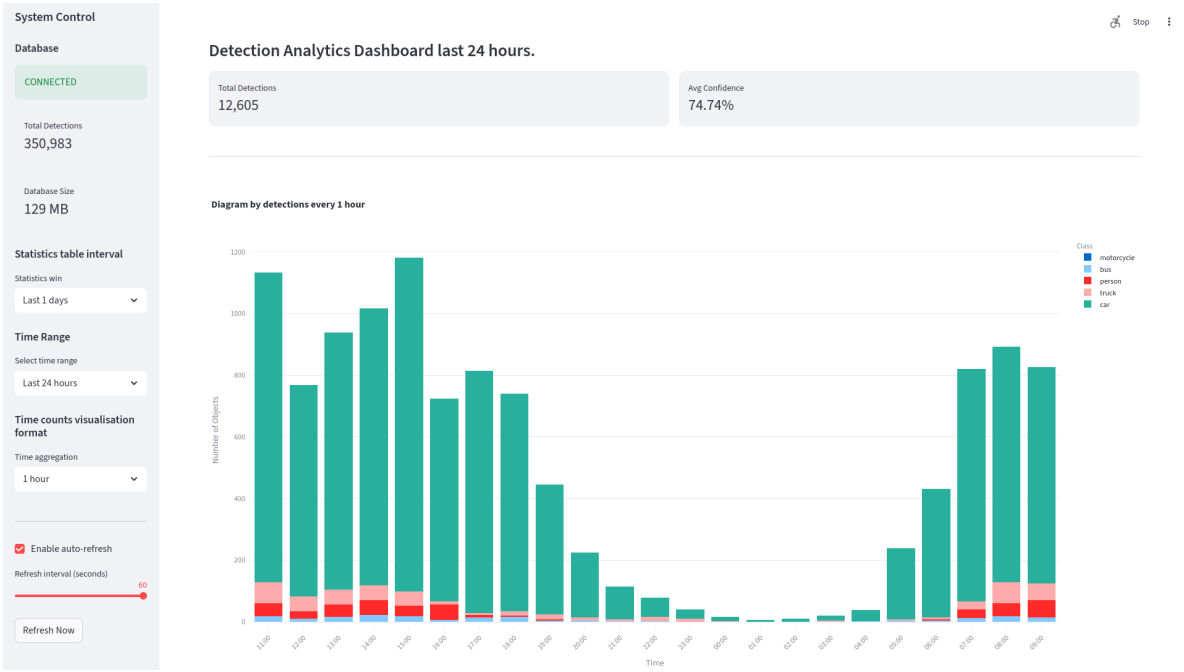
Na serverové straně přijímá zprávy samostatný proces (MQTT subscriber). Pro zajištění vysoké propustnosti při komunikaci s databází PostgreSQL využívá aplikace mechanismus *connection poolingu* (opakované využívání otevřených databázových spojení). Samotný zápis dat do tabulky `detections` (jejíž schéma bylo definováno v kapitole 2.3) je realizován pomocí dávkového vkládání (`execute_batch`) z knihovny Psycopg, které umožňuje vložit až 100 záznamů v rámci jediné databázové transakce (ukázka 3.12).

Listing 3.12: Dávkové vkládání detekčních záznamů do databáze PostgreSQL.

```
query = """
INSERT INTO detections
(timestamp_, frame_id, class_name, confidence, x1, y1, x2, y2, track_id
    )
VALUES (%s, %s, %s, %s, %s, %s, %s, %s, %s)
"""
execute_batch(cursor, query, data, page_size=100)
conn.commit()
```

Implementace vizualizačního dashboardu

Uživatelské rozhraní vytvořené ve frameworku Streamlit (obrázek 3.1) načítá uložená data z backendu (FastAPI framework) prostřednictvím REST API endpointů (`/api/detections` a `/api/statistics`). Přijatá JSON data jsou převedena do struktury `DataFrame` knihovny Pandas, kde probíhá konverze časových razítek na typ `datetime`.



Obrázek 3.1.: Ukázka implementovaného vizualizačního dashboardu systému.

Pro dynamickou analýzu vývoje dopravy v čase využívá aplikace metodu `resample()`, jež umožňuje uživateli měnit šířku časového okna agregace (např. 1 minuta, 10 minut, 1 hodina) jak globálně, tak pro jednotlivé kategorie vozidel (ukázka 3.13).

Listing 3.13: Časová agregace detekcí podle tříd vozidel v knihovně Pandas.

```
df_timeline = df.set_index("timestamp")

df_class_timeline = (
    df_timeline.groupby('class_name')
    .resample(selected_interval)
    .size()
    .reset_index(name="count")
)
```

Agregovaná časová řada je následně vykreslena pomocí knihovny Plotly jako skládaný sloupcový graf (*stacked bar chart*), který přehledně zobrazuje celkovou intenzitu provozu i poměrné zastoupení jednotlivých typů vozidel v daných časových intervalech (ukázka 3.14).

Listing 3.14: Generování skládaného sloupcového grafu pomocí knihovny Plotly.

```
fig = px.bar(
    df_class_timeline,
    x="timestamp",
    y="count",
    color="class_name",
    barmode="stack"
)
```

4. Testování a vyhodnocení

Zatímco v reálném nasazení na zařízení Raspberry Pi 5 pracuje navržený systém v nepřetržitém režimu, kde v reálném čase odesílá detekční události přes protokol MQTT do databáze a vizualizačního dashboardu, pro účely exaktního a opakovatelného měření přesnosti a výkonu bylo provedeno kontrolované offline vyhodnocení nad zaznamenaným videem.

4.1. Testovací scénáře a vliv oblasti zájmu (ROI)

Pro experimentální vyhodnocení byla použita reprezentativní přibližně čtyřminutová video sekvence zachycující reálnou dopravní situaci na okružní křižovatce za zhoršených zimních povětrnostních podmínek (husté sněžení, snížený kontrast a mokrá vozovka). Pro stanovení referenční hodnoty (*ground truth*, GT) byla všechna projíždějící vozidla a chodci v této sekvenci nejprve manuálně spočítáni a klasifikováni lidským pozorovatelem, přičemž bylo zaznamenáno celkem **118 reálných objektů** (108 osobních automobilů, 3 autobusy, 6 nákladních vozidel a 1 chodec).

Stejná dopravní situace byla následně analyzována a porovnána pomocí dvou odlišných hardwarových a softwarových přístupů:

- **Edge řešení (Hailo-8):** Detekce probíhala na cílovém zařízení Raspberry Pi 5 s AI akcelerátorem Hailo-8, kvantizovaným modelem YOLOv8m (INT8, formát HEF) a sledovacím modulem `hailotracker` v rámci GStreamer pipeline.
- **Referenční GPU řešení:** Detekce byla realizována na osobním počítači vybaveném grafickou kartou (GPU) v plné přesnosti (FP32/FP16) s využitím knihoven Ultralytics a OpenCV, robustnějšího modelu YOLOv11l a sledovacího algoritmu ByteTrack.

Specifika a vliv geometrie ROI: Při testování byly u obou platforem použity mírně odlišné geometrie oblasti zájmu (ROI). U referenčního GPU řešení byla definována obdélníková ROI pokrývající výjezd z okružní křižovatky. U Edge řešení (Hailo-8) však v okrajových částech obdélníku docházelo vlivem mírně nižší prostorové stability kvantizovaných ohraničujících rámečků k častější ztrátě sledovacího identifikátoru (*ID switch*). Z tohoto důvodu byla pro Hailo-8 definována zúžená polygonální ROI zóna přesně kopírující střed jízdního pruhu. Toto zmenšení aktivní plochy mělo přímý měřitelný vliv: zkrácením dráhy, po kterou je vozidlo uvnitř zóny vyhodnocováno, se podařilo významně potlačit vícenásobné započítání téhož vozidla (*ghosting*), avšak za cenu toho, že objekty pohybující se na samém okraji komunikace (např. chodec na chodníku) se ocitly mimo vymezený polygon.

4.2. Vyhodnocení přesnosti detekce a matice záměn

Pro posouzení kvality samotné detekce byly z vyexportovaných telemetrických souborů (`hailo_statistics.js` a `gpu_stats.json`) analyzovány celkové počty hrubých snímkových detekcí, průměrné míry spolehlivosti (*average confidence*) a výsledné komponenty matice záměn (*Confusion Matrix*) vůči ručně stanovenému počtu 118 objektů.

Z hlediska míry spolehlivosti (*confidence score*) jednotlivých snímkových predikcí dosáhly oba modely vysoce vyrovnaných výsledků, jak dokládá tabulka 4.1. Vážený průměr spolehlivosti napříč všemi detekovanými snímky činil **0,773** u akcelerátoru Hailo-8 (nevážený průměr detekovaných tříd vozidel **0,74**) a **0,751** u referenčního GPU řešení (nevážený průměr tříd vozidel **0,73**). To prokazuje, že post-tréninková kvantizace modelu YOLOv8m do formátu INT8 nevedla ke snížení jistoty predikcí neuronové sítě.

Třída	Snímkové det. (Hailo)	Prům. conf. (Hailo)	Snímkové det. (GPU)	Prům. conf. (GPU)
Car	4 349	0,7787	5 658	0,7582
Bus	127	0,7400	219	0,7544
Truck	304	0,7057	543	0,6817
Person	0	–	23	0,5573
Celkem	**4 780**	**0,7415 (váž. 0,773)**	**6 443**	**0,7314 (váž. 0,751)**

Tabulka 4.1.: Přehled celkového počtu snímkových detekcí a průměrné míry spolehlivosti (confidence) dle JSON logů.

Pro výpočet standardních klasifikačních metrik nad unikátními sledovanými objekty byla sestavena matice záměn (tabulka 4.2). Pro každou třídu představuje hodnota **TP** (*True Positives*) počet správně zachycených reálných objektů $\min(\mathrm{GT}, N_{\mathrm{sys}})$, hodnota **FP** (*False Positives*) počet falešných či duplicitních detekcí nad rámec skutečnosti $\max(0, N_{\mathrm{sys}} - \mathrm{GT})$ a hodnota **FN** (*False Negatives*) počet nezachycených objektů $\max(0, \mathrm{GT} - N_{\mathrm{sys}})$. Vzhledem k povaze úlohy detekce objektů v obraze se prázdné pozadí (**TN**) neuvažuje ($\mathrm{TN} = 0$).

		Edge řešení (Hailo-8)			Referenční GPU řešení		
Třída objektu	**Ruční (GT)**	**TP**	**FP**	**FN**	**TP**	**FP**	**FN**
Car	108	108	12	0	108	0	0
Bus	3	3	1	0	3	8	0
Truck	6	3	0	3	6	6	0
Person	1	0	0	1	1	0	0
Celkem	**118**	**114**	**13**	**4**	**118**	**14**	**0**

Tabulka 4.2.: Matice záměn (TP, FP, FN) pro unikátní sledované objekty vůči referenčnímu sčítání (GT = 118).

Z agregovaných složek matice záměn ($\text{TP}_{\text{Hailo}} = 114, \text{FP}_{\text{Hailo}} = 13, \text{FN}_{\text{Hailo}} = 4$ pro celkem 127 detekcí Hailo a $\text{TP}_{\text{GPU}} = 118, \text{FP}_{\text{GPU}} = 14, \text{FN}_{\text{GPU}} = 0$ pro celkem 132 detekcí GPU) byly vypočítány výsledné hodnoticí metriky:

- **Precision (Přesnost):** $\text{Precision} = \frac{\text{TP}}{\text{TP+FP}}$
  - *Edge řešení (Hailo-8):* $\frac{114}{114+13} = \frac{114}{127} = \mathbf{89{,}76}\ \%$
  - *Referenční GPU řešení:* $\frac{118}{118+14} = \frac{118}{132} = \mathbf{89{,}39}\ \%$
- **Recall (Úplnost):** $\text{Recall} = \frac{\text{TP}}{\text{TP+FN}}$
  - *Edge řešení (Hailo-8):* $\frac{114}{114+4} = \frac{114}{118} = \mathbf{96{,}61}\ \%$
  - *Referenční GPU řešení:* $\frac{118}{118+0} = \frac{118}{118} = \mathbf{100{,}00}\ \%$
- **F1-skóre (Harmonický průměr Precision a Recall):** $\text{F1} = \frac{2 \cdot \text{TP}}{2 \cdot \text{TP+FP+FN}}$
  - *Edge řešení (Hailo-8):* $\frac{228}{228+13+4} = \frac{228}{245} = \mathbf{93{,}06}\ \%$
  - *Referenční GPU řešení:* $\frac{236}{236+14+0} = \frac{236}{250} = \mathbf{94{,}40}\ \%$
- **Detekční Accuracy (Critical Success Index při TN $= 0$):** $\text{Accuracy} = \frac{\text{TP}}{\text{TP+FP+FN}}$
  - *Edge řešení (Hailo-8):* $\frac{114}{114+13+4} = \frac{114}{131} = \mathbf{87{,}02}\ \%$
  - *Referenční GPU řešení:* $\frac{118}{118+14+0} = \frac{118}{132} = \mathbf{89{,}39}\ \%$

4.3. Vyhodnocení přesnosti sčítání a klasifikace

Navazujícím krokem bylo vyhodnocení celkové provozní přesnosti sčítání dopravy pomocí poměrové metriky $\text{Accuracy}_{\text{count}}$, definované v teoretické části práce vztahem:

$$\text{Accuracy}_{\text{count}} = \left(1 - \frac{|N_{\text{real}} - N_{\text{sys}}|}{N_{\text{real}}}\right) \cdot 100\ [\%]$$

kde N_{real} představuje skutečný počet objektů dle manuální anotace ($\text{GT} = 118$) a N_{sys} celkový počet unikátních objektů (`unique_objects_tracked`) zaznamenaných systémem. Porovnání výsledků pro jednotlivé třídy i celkový součet uvádí tabulka 4.3.

Třída objektu	**Ruční (GT)**	**Hailo-8 (Edge)**	**GPU (Ref.)**	**Odchylka Hailo**	**Odchylka GPU**
Car (osobní vůz)	108	120	108	+12	0
Bus (autobus)	3	4	11	+1	+8
Truck (nákladní vůz)	6	3	12	−3	+6
Person (chodec)	1	0	1	−1	0
Celkem (N)	**118**	**127**	**132**	**+9**	**+14**
$\text{Accuracy}_{\text{count}}$	**100,00 %**	**92,37 %**	**88,14 %**	–	–

Tabulka 4.3.: Porovnání počtu započítaných unikátních objektů s referenční hodnotou (ground truth).

Při interpretaci výsledků v tabulce 4.3 je nezbytné striktně rozlišovat mezi **celkovou sumární přesností sčítání** a **přesností v rámci jednotlivých tříd (*per-class accuracy*)**, neboť každá z platforem vykazuje odlišný typ chybovosti:

1. **Celkový počet vozidel (Accuracy$_{\text{count}}$):** V celkovém součtu všech detekovaných objektů dosáhlo vyšší poměrové přesnosti **Edge řešení s akcelerátorem Hailo-8 (92,37 %)** oproti **GPU řešení (88,14 %)**. Celkový součet na platformě Hailo-8 (127 objektů) se přiblížil skutečnosti (118 objektů) s celkovou odchylkou pouhých $+9$ objektů, zatímco GPU řešení celkový počet nadhodnotilo o $+14$ objektů (132 detekcí).
2. **Přesnost na dominantní třídě *Car* a vliv ghostingu:** Při pohledu na nejpočetnější kategorii osobních automobilů (*Car*) dosáhlo **GPU řešení 100% shody s referenční hodnotou** (108 ze 108 vozidel, FP $= 0$). Kombinace modelu YOLOv11l a algoritmu ByteTrack dokázala bezchybně udržet identitu osobních vozidel po celou dobu průjezdu. Naopak řešení Hailo-8 s modulem `hailotracker` zaznamenalo 120 osobních vozidel (Accuracy$_{\text{count(Car)}} = 88{,}89\ \%$). Tato odchylka (FP $= +12$ vozidel) byla způsobena jevem tzv. *ghostingu* (fragmentace stopy), kdy při hustém sněžení či částečném zákrytu vozidla za sloupem veřejného osvětlení došlo ke krátkodobému výpadku detekce a následnému přidělení nového `track_id` témuž vozidlu.
3. **Rozbor anomálií u tříd *Bus* a *Truck*:** Zásadním zjištěním experimentu je vysoký počet falešně pozitivních klasifikací (*False Positives*) u GPU řešení v kategoriích *Bus* (11 detekcí oproti GT 3, FP $= +8$) a *Truck* (12 detekcí oproti GT 6, FP $= +6$). Detailní revize výstupních dat ukázala dvě příčiny tohoto jevu:
   - *Mezitřídní záměna (Class Confusion):* Model YOLOv11l vykazoval v šikmém pohledu kamery a za hustého sněžení zvýšenou citlivost na rozměrnější vozidla – běžné dodávky, vozidla SUV či osobní automobily se sněhovou pokrývkou byly v několika snímcích chybně klasifikovány jako *Truck* nebo *Bus*.
   - *Změna třídy během sledování (Class Switching):* Pokud bylo jedno projíždějící vozidlo (např. dodávka) v první polovině průjezdu obdélníkovou zónou ROI klasifikováno jako *Car* a ve druhé polovině jako *Truck*, došlo v agregační logice k jeho evidenci v obou kategoriích. To uměle navýšilo součty tříd *Bus* a *Truck* na GPU o 14 falešných detekcí a snížilo jeho celkovou metriku Accuracy$_{\text{count}}$ na 88,14 %. Na platformě Hailo-8 (s menší polygonální ROI) k tomuto jevu docházelo minimálně (4 autobusy oproti GT 3, u nákladních vozů 3 oproti GT 6). Chodec pohybující se po chodníku mimo zúžený polygon nebyl na Hailo-8 započítán (FN $= 1$), zatímco širší obdélníková ROI na GPU jej zachytila.

4.4. Vyhodnocení výkonnosti systému

Schopnost zpracovávat obrazový tok v reálném čase byla vyhodnocena na základě telemetrických logů (`hailo_statistics.json` a `gpu_stats.json`) vygenerovaných během běhu obou pipeline.

Rozdíl v celkovém počtu zpracovaných snímků mezi oběma záznamy (4 957 snímků u Hailo-8 při 20 FPS zdrojového výstupu oproti 2 977 snímkům u GPU při 15 FPS převzorkovaného záznamu) je dán odlišným nastavením snímkové frekvence kontejneru při exportu testovací sekvence, avšak průměrná propustnost (FPS) a doba zpracování jednoho snímku jsou plně porovnatelné. Přehled naměřených hodnot shrnuje tabulka 4.4.

Měřený parametr	**Edge (RPi 5 + Hailo-8)**	**Referenční GPU**
Použitý detekční model	YOLOv8m (INT8, HEF)	YOLOv11l (FP32/FP16)
Rozlišení vstupního tenzoru	640×640 px	640×640 px
Celkový počet zpracovaných snímků	4 957	2 977
Snímky s detekcí objektu	3 594 (72,5 %)	2 953 (99,2 %)
Celková doba zpracování (`processing_time`)	168,65 s	206,38 s
Průměrná propustnost (**FPS**)	**29,39 FPS**	**14,42 FPS**
Průměrná doba zpracování snímku (latence)	∼34,02 ms	∼69,35 ms
Využití CPU (Raspberry Pi 5)	25–35 %	–
Typický příkon celé sestavy	∼8–12 W	$>$ 150 W

Tabulka 4.4.: Porovnání výpočetní výkonnosti a provozních parametrů obou platforem dle JSON logů.

Naměřené výsledky prokazují, že navržené Edge řešení s akcelerátorem Hailo-8 dosahuje průměrné propustnosti **29,39 FPS** (doba zpracování jednoho snímku 34,02 ms), čímž s výraznou rezervou splňuje teoretický požadavek na zpracování v reálném čase (definovaný v kapitole 1.5 jako latence pod 50 ms, tj. minimálně 20 FPS). Naproti tomu referenční řešení s výpočetně masivním modelem YOLOv11l a neoptimalizovanou smyčkou v knihovně OpenCV dosáhlo průměrné rychlosti **14,42 FPS** (69,35 ms na snímek).

Vliv AI akcelerátoru a GStreameru na vytížení CPU: Zásadním přínosem integrace modulu Hailo-8 (26 TOPS) přes sběrnici PCIe je téměř úplné odlehčení hlavnímu procesoru ARM Cortex-A76 na desce Raspberry Pi 5. Zatímco samotný výpočet konvolučních vrstev modelu YOLOv8m pouze na CPU by vedl k 100% vytížení všech jader a propadu snímkové frekvence na řádově 1 až 2 FPS, při využití akcelerátoru Hailo-8 a nativních C/C++ pluginů frameworku GStreamer se průměrné vytížení CPU pohybuje pouze v rozmezí 25 až 35 %. Procesor tak obsluhuje pouze dekódování síťového RTSP streamu, geometrickou filtraci v knihovně Shapely a asynchronní odesílání JSON zpráv přes MQTT, což zajišťuje nízké zahřívání a dlouhodobou provozní stabilitu při zlomkové spotřebě elektrické energie oproti desktopovému GPU řešení.

5. Diskuze a prezentace výsledků

Experimentální vyhodnocení odhalilo klíčové kompromisy mezi nasazením systému na nízkoenergetické okrajové platformě (Edge AI) a provozem na výkonné grafické kartě (GPU).

Z hlediska celkového sčítání dopravního proudu dosáhlo navržené Edge řešení s akcelerátorem Hailo-8 velmi vysoké poměrové přesnosti **92,37 %** (127 detekovaných objektů oproti 118 skutečným, Precision $= 89{,}76\ \%$, Recall $= 96{,}61\ \%$), čímž v sumární metrice $\text{Accuracy}_{\text{count}}$ překonalo referenční GPU řešení (**88,14 %**, 132 detekovaných objektů, Precision $= 89{,}39\ \%$, Recall $= 100{,}00\ \%$). Detailní analýza výsledků prostřednictvím matice záměn však ukázala, že obě platformy vykazují zcela odlišnou strukturu chyb:

- **Stabilita sledování vs. klasifikační přecitlivělost (GPU):** Referenční GPU řešení s modelem YOLOv11l a algoritmem ByteTrack dosáhlo na hlavní třídě osobních vozidel (*Car*) 100% přesnosti (108 ze 108 vozidel) a nulového počtu přehlédnutých objektů napříč celým videem (FN $= 0$). To potvrzuje vysokou odolnost algoritmu ByteTrack vůči ztrátě identity. Na druhé straně však model YOLOv11l trpěl v nepříznivých zimních podmínkách četnými mezitřídními záměnami u větších vozidel (dodávky a SUV byly falešně klasifikovány jako autobusy či nákladní vozy – celkem 14 falešně pozitivních detekcí v kategoriích *Bus* a *Truck*).
- **Kvantizace a efekt ghostingu (Hailo-8):** Na okrajovém zařízení s modelem YOLOv8m (INT8) a modulem `hailotracker` byla klasifikace vzácnějších tříd (*Bus*, *Truck*) vyrovnanější (FP $= 1$ u autobusů, FN $= 3$ u nákladních vozů), avšak u dominantní třídy *Car* došlo k nadhodnocení počtu o 12 vozidel (120 oproti 108). Příčinou byl tzv. *ghosting efekt* – při hustém sněžení a zákrytech vozidel docházelo k mírnému kolísání velikosti predikovaných ohraničujících rámečků, což vedlo k dočasnému poklesu překryvu (IoU) pod prahovou hodnotu sledovacího algoritmu a následnému přidělení nového identifikátoru témuž vozidlu.
- **Vliv geometrie ROI:** Aby byl výše popsaný efekt ghostingu na platformě Hailo-8 minimalizován, byla v implementaci použita prostorově zúžená polygonální oblast zájmu (ROI). Toto opatření se ukázalo jako velmi efektivní pro stabilizaci celkového součtu a dosažení rychlosti 29,39 FPS, avšak způsobilo nezachycení chodce pohybujícího se po okraji komunikace mimo polygon (FN $= 1$). Pro plně deterministické srovnání obou platforem v budoucích experimentech bude vhodné sjednotit definici souřadnic ROI na identický polygon a řešit potlačení duplicit úpravou hyperparametrů samotného trackeru (zejména prodloužením paměti ztracených stop, tzv. *track buffer*).

Z pohledu praktického nasazení v reálné infrastruktuře chytrých měst představuje kombinace Raspberry Pi 5 a akcelerátoru Hailo-8 jednoznačně vhodnější variantu. Při spotřebě okolo 10 W

a rychlosti 29,39 FPS dokáže autonomně a v reálném čase zpracovávat obraz přímo u kamery v souladu s principy GDPR (*Privacy by Design*), přičemž přesnost sčítání přesahující 92 % v náročných zimních podmínkách je pro účely dlouhodobého sledování intenzity dopravy a identifikaci dopravních špiček plně dostačující.

6. Závěr

Cílem této bakalářské práce bylo navrhnout, implementovat a experimentálně ověřit komplexní systém pro automatizované monitorování a analýzu silniční dopravy v reálném čase, postavený na principech zpracování obrazu na okraji sítě (*Edge AI*). Všechny stanovené cíle práce byly úspěšně splněny.

V první části práce byla zpracována teoretická rešerše zaměřená na moderní jednofázové detekční architektury (zejména rodinu modelů YOLO), algoritmy víceobjektového sledování (SORT, DeepSORT, ByteTrack) a metody prostorového vyhodnocování průjezdů pomocí oblastí zájmu (ROI). Zvláštní pozornost byla věnována hardwarové akceleraci neuronových sítí na vestavěných zařízeních a dodržení legislativních požadavků GDPR prostřednictvím konceptu *Privacy by Design*.

V rámci praktické části byla navržena a implementována modulární vícevrstvá architektura systému. Pro výpočetní uzel na hraně sítě (Raspberry Pi 5 s AI akcelerátorem Hailo-8) byl model YOLOv8m exportován do formátu ONNX a následně pomocí nástroje Hailo Dataflow Compiler kvantizován do 8bitové přesnosti (INT8) a zkompilován do binárního formátu HEF. Zpracování živého RTSP video streamu z IP kamery bylo realizováno pomocí vysokoúrovňového řetězce v multimediálním frameworku GStreamer, doplněného o geometrickou filtraci průjezdů v polygonální ROI zóně s využitím knihovny Shapely. Pro přenos anonymizovaných detekčních metadat byl nasazen asynchronní protokol MQTT, na který navazuje databázová vrstva s relační databází PostgreSQL (využívající dávkové vkládání a indexaci časových řad), backendové REST API ve frameworku FastAPI a interaktivní analytický dashboard vytvořený pomocí nástrojů Streamlit a Plotly.

Funkčnost a přesnost celého řešení byly ověřeny na reálném dopravním videozáznamu pořízeném za zhoršených zimních povětrnostních podmínek (sněžení) a porovnány s referenční implementací na grafické kartě (GPU) i manuálním sčítáním (*ground truth*). Navržené Edge řešení s akcelerátorem Hailo-8 dosáhlo celkové poměrové přesnosti sčítání $\text{Accuracy}_{\text{count}} = 92{,}37\ \%$ při plném zachování schopnosti zpracování v reálném čase a nízkém vytížení hlavního procesoru. Práce zároveň detailně analyzovala příčiny odchylek obou platforem – zejména vliv fragmentace stop (*ghostingu*) u jednoduššího sledovacího modulu na straně Hailo a naopak zvýšenou míru mezitřídních záměn u méně zastoupených kategorií vozidel (*Bus*, *Truck*) na straně referenčního modelu.

Hlavním praktickým přínosem práce je vytvoření plně autonomního, finančně dostupného a energeticky úsporného monitorovacího uzlu, který nevyžaduje přenos citlivého videozáznamu do cloudu a lze jej díky automatizačním skriptům okamžitě nasadit v reálné dopravní infrastruktuře.

V budoucnu lze vytvořený systém dále rozšířit několika směry:

- **Vlastní dotrénování modelu (*fine-tuning*):** Dotrénování modelu YOLO na specifickém lokálním datasetu z českých komunikací za účelem potlačení mezitřídních záměn mezi dodávkami, osobními vozy a nákladními automobily.
- **Pokročilá správa trajektorií a vektoru směru:** Rozšíření aplikační logiky v zóně ROI o vyhodnocování směrových vektorů pohybu (rozlišení vjezdů a výjezdů na jednotlivých ramenech křižovatky) a nasazení pokročilejšího sledovacího algoritmu přímo do GStreamer pipeline pro eliminaci ghostingu.
- **Horizontální škálování:** Využití připravených databázových atributů (`device_name`, `model_name`) pro zapojení většího počtu okrajových jednotek Raspberry Pi z různých lokalit města do jednoho centrálního analytického dashboardu.

Seznam použitých zdrojů

1. SZELISKI, Richard. *Computer Vision: Algorithms and Applications*. 2. vyd. Cham, Switzerland: Springer, 2022. ISBN 978-3-030-34372-9.
2. ZHOU, Wei; YANG, Li; ZHAO, Lei; ZHANG, Runyu; CUI, Yifan; HUANG, Hongpu; QIE, Kun; WANG, Chen. Vision Technologies with Applications in Traffic Surveillance Systems: A Holistic Survey. 2025. Dostupné z arXiv: 2412.00348 [cs.CV].
3. REDMON, Joseph; DIVVALA, Santosh; GIRSHICK, Ross; FARHADI, Ali. You Only Look Once: Unified, Real-Time Object Detection. 2016, 779–788. Dostupné z DOI: 10.1109/CVPR.2016.91.
4. BEWLEY, Alex; GE, Zongyuan; OTT, Lionel; RAMOS, Fabio; UPCROFT, Ben. Simple Online and Realtime Tracking. *2016 IEEE International Conference on Image Processing (ICIP)*. 2016, 3464–3468. Dostupné z DOI: 10.1109/ICIP.2016.7533003.
5. PEREIRA, Ricardo; CARVALHO, Guilherme; GARROTE, Luís; NUNES, Urbano J. Sort and Deep-SORT Based Multi-Object Tracking for Mobile Robotics: Evaluation with New Data Association Metrics. *Applied Sciences*. 2022, **12**(3), 1319. Dostupné z DOI: 10.3390/app12031319.
6. WOJKE, Nicolai; BEWLEY, Alex; PAULUS, Dietrich. Simple online and realtime tracking with a deep association metric. In: *2017 IEEE International Conference on Image Processing (ICIP)*. 2017, s. 3645–3649. Dostupné z DOI: 10.1109/ICIP.2017.8296962.
7. LIN, Tsung-Yi; MAIRE, Michael; BELONGIE, Serge; HAYS, James; PERONA, Pietro; RAMANAN, Deva; DOLLÁR, Piotr; ZITNICK, C. Lawrence. Microsoft COCO: Common Objects in Context. In: *Lecture Notes in Computer Science* [online]. Cham: Springer International Publishing, 2014, s. 740–755 [cit. 2026-04-15]. ISBN 978-3-319-10601-4. ISSN 0302-9743. Dostupné z DOI: 10.1007/978-3-319-10602-1_48.
8. GS INDUSTRIES. *Security cameras watching from above to everywhere* [https://www.gsindustries.com.au/news/cameras-on-top-of-street-light-poles/]. [B.r.]. [Online; cit. 2026-10-13].
9. LI, En; ZENG, Liekang; ZHOU, Zhi; CHEN, Xu. Edge AI: On-Demand Accelerating Deep Neural Network Inference via Edge Computing. *IEEE Transactions on Wireless Communications*. 2020, **19**(1), 447–457. Dostupné z DOI: 10.1109/TWC.2019.2946140.

10. HAILO TECHNOLOGIES LTD. *Automatic License Plate Recognition with Hailo Processors* [online]. Hailo Blog, 2024. [cit. 2025-12-04]. Dostupné z: https://hailo.ai/ja/blog/automatic-license-plate-recognition-with-hailo-processors/.

11. AKIRA AI. *Edge Computing vs. Cloud Computing* [online]. 2025. [cit. 2026-02-05]. Dostupné z: https://www.akira.ai/insights/edge-computing-vs-cloud-computing/.

12. HAILO TECHNOLOGIES LTD. *Dataflow AI Architecture & Chip Design*. 2026. Dostupné také z: https://hailo.ai/products/technology/. [Online; cit. 2026-10-14].

13. RASPBERRY PI FOUNDATION. *Raspberry Pi Documentation* [online]. Cambridge, 2024 [cit. 2025-11-03]. Dostupné z: https://www.raspberrypi.com/documentation/.

14. RASPBERRY PI FOUNDATION. *AI Kit and AI HAT+ Software* [online]. [cit. 2025-12-04]. Dostupné z: https://www.raspberrypi.com/documentation/computers/ai.html.

15. RPISHOP.CZ. *Rozšiřující modul Raspberry Pi AI HAT+ s integrovaným procesorem Hailo-8* [online]. 2025. [cit. 2026-02-07]. Dostupné z: https://rpishop.cz/554037/raspberry-pi-ai-hat-26-tops/?utm_source=google&utm_medium=cpc&utm_campaign=CZ-GS-No%2Funder%20index%20produkty&utm_id=21746766956&gad_source=1&gad_campaignid=21746766956&gclid=CjwKCAjw3ejRBhAdEiwADkqPn2lUaqSqkp41Y9Hslvr5GanWu-a1OWg7rKaN3wuao8QdzkvLJJwgWBoCuYsQAvD_BwE.

16. PRONELLO, Cristina; GARZÓN RUIZ, Ximena Rocio. Evaluating the Performance of Video-Based Automated Passenger Counting Systems in Real-World Conditions: A Comparative Study. *Sensors*. 2023, **23**(18), 7719. ISSN 1424-8220. Dostupné z DOI: 10.3390/s23187719.

17. NAMATĒVS, Ivars; KADIĶIS, Roberts; ZENCOVS, Anatolijs; LEJA, Laura; DOBRĀJS, Artis. Dataset of Annotated Virtual Detection Line for Road Traffic Monitoring. *Data*. 2022, **7**(4). ISSN 2306-5729. Dostupné z DOI: 10.3390/data7040040.

18. OASIS OPEN. *MQTT Version 5.0* [online]. 2019. [cit. 2025-11-04]. Dostupné z: https://docs.oasis-open.org/mqtt/mqtt/v5.0/mqtt-v5.0.html.

19. PSYCOPG TEAM. *Psycopg Documentation: PostgreSQL Database Adapter for Python* [online]. 2025. [cit. 2025-11-04]. Dostupné z: https://www.psycopg.org/.

20. HARRIS, Charles R.; MILLMAN, K. Jarrod; WALT, Stéfan J. van der et al. Array Programming with NumPy. *Nature*. 2020, 357–362. Dostupné z DOI: 10.1038/s41586-020-2649-2.

21. MCKINNEY, Wes. Data Structures for Statistical Computing in Python. 2010, 56–61. Dostupné z DOI: 10.25080/Majora-92bf1922-00a.

22. PLOTLY TECHNOLOGIES INC. *Collaborative Data Science* [online]. Montréal, QC, 2015 [cit. 2025-11-04]. Dostupné z: https://plot.ly.

23. PYTHON SOFTWARE FOUNDATION. *Python 3.13 Documentation* [online]. 2025. [cit. 2025-11-03]. Dostupné z: https://docs.python.org/3.13/.

24. HAILO TECHNOLOGIES LTD. *TAPPAS User Guide* [online]. 3.31.0. vyd. Hailo, 2024. [cit. 2026-02-03]. Dostupné z: `https://hailo.ai`. Software documentation.

25. HAILO TECHNOLOGIES LTD. *Hailo Raspberry Pi 5 Examples* [online]. 2024. [cit. 2026-03-01]. Dostupné z: `https://github.com/hailo-ai/hailo-rpi5-examples`.

26. HAILO TECHNOLOGIES LTD. *Hailo Dataflow Compiler User Guide* [online]. 2024. [cit. 2026-03-01]. Dostupné z: `https://hailo.ai`.

27. HAILO TECHNOLOGIES LTD. *Hailo Model Zoo* [online]. 2024. [cit. 2026-03-01]. Dostupné z: `https://github.com/hailo-ai/hailo_model_zoo`.

A. Externí přílohy

Zdrojové kódy navrženého systému, konfigurační skripty, dokumentace architektury, vyexportované výsledky měření i samotný text této bakalářské práce jsou uloženy v přiloženém elektronickém archivu (a verzovány v repozitáři systému Git). Struktura hlavních adresářů a souborů je popsána v tabulce A.1.

Cesta v úložišti	**Popis obsahu a funkce**
`rpi_src/`	Zdrojové kódy určené pro okrajové zařízení Raspberry Pi 5 s akcelerátorem Hailo-8 (konstrukce GStreamer pipeline, detekční smyčka, MQTT klient, správce databáze PostgreSQL, FastAPI backend a Streamlit dashboard).
`pc_src/`	Skripty pro referenční vyhodnocení a testování detekčních modelů na osobním počítači s využitím GPU, knihoven Ultralytics, OpenCV a algoritmu ByteTrack.
`pipelene_tested_videos/`	Výstupní data z experimentálního testování, telemetrické a statistické soubory ve formátu JSON a testovací obrazové výstupy.
`docs/`	Technická dokumentace projektu obsahující architektonická schémata a zdrojové definice UML diagramů tříd a sekvenčních diagramů (ve formátu Mermaid).
`thesis_text/`	Zdrojové kódy textu této bakalářské práce v systému LaTeX (`Bachelor_thesis.tex`), bibliografická databáze (`references.bib`) a grafické přílohy (`images/`).
`thesis_literature_resources/`	Složka s referenčními odbornými články, studiemi a dokumentací použitými při zpracování teoretické rešerše.

Tabulka A.1.: Struktura přiloženého elektronického úložiště projektu.